



HUTECH UNIVERSITY
Faculty of Data Science

**Thu thập dữ liệu thông tin các nhà sáng tạo nội
dung trên Tiktok từ website TiktokOne bằng
Selenium và MongoDB**

SINH VIÊN THỰC HIỆN:

Lâm Trần Tấn Phát - 2386400038

Đỗ Quốc Khánh - 2386400023

Đoàn Phú - 2386400719

Supervisor: Lê Nhật Tùng

Ngày 29 tháng 12 năm 2025

NHẬN XÉT CỦA GIÁO VIÊN HƯỚNG DẪN

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

TPHCM, Ngày _____ tháng _____ năm 2024

Giáo viên hướng dẫn
(Ký tên, đóng dấu)

MỤC LỤC

DANH MỤC CÁC KÝ HIỆU VÀ CHỮ VIẾT TẮT

iv

I	Giới thiệu	1
I-A	TikTok	1
I-B	TikTokOne (Creator Marketplace)	1
I-C	Selenium	2
I-D	MongoDB	2
I-E	Mục tiêu và Đóng góp của Nghiên cứu	2
II	Cơ sở lý thuyết	4
II-A	Tổng quan về Influencer Marketing	4
II-A1	Định nghĩa và Sự chuyển dịch mô hình	4
II-A2	Phân loại Influencer theo Dữ liệu	4
II-A3	Các chỉ số đo lường hiệu quả (KPIs)	4
II-B	Hệ sinh thái TikTok và Social Commerce	5
II-B1	Mô hình Shoppertainment	5
II-B2	Thuật toán phân phối: Interest Graph	5
II-B3	Cơ chế Lưu lượng (Traffic Pool Mechanism)	5
II-C	Cơ sở lý thuyết về Web Scraping	5
II-C1	Kiến trúc Website hiện đại và DOM	5
II-C2	Kỹ thuật định vị phần tử (Element Locators)	5
II-C3	So sánh các công cụ thu thập dữ liệu	6
II-C4	Khía cạnh Đạo đức và Pháp lý	6
II-D	Cơ sở dữ liệu NoSQL và MongoDB	6
II-D1	Định lý CAP và Hạn chế của RDBMS	6
II-D2	Mô hình dữ liệu hướng tài liệu (Document-Oriented)	6
II-D3	Cơ chế Đánh chỉ mục (Indexing)	7
II-D4	Aggregation Framework	7
III	Phân tích và Thiết kế hệ thống	8
III-A	Phân tích yêu cầu	8
III-A1	Yêu cầu chức năng	8
III-A2	Yêu cầu phi chức năng	8
III-B	Mô hình hóa hệ thống (UML)	8
III-B1	Đặc tả Use Case Thu thập dữ liệu	8
III-C	Thiết kế Cơ sở dữ liệu	8
III-C1	Chi tiết cấu trúc Document	8
III-D	Thiết kế Kiến trúc phần mềm	9
III-D1	1. Tầng Giao diện (Presentation Layer)	9
III-D2	2. Tầng Nghiệp vụ (Business Logic Layer)	9
III-D3	3. Tầng Truy cập Dữ liệu (Data Access Layer - DAL)	9
IV	Phương pháp nghiên cứu	10
IV-A	Kiến trúc hệ thống	10
IV-B	Quy trình thu thập dữ liệu (Crawling)	11
IV-C	Kỹ thuật tiền xử lý dữ liệu (Preprocessing)	12

IV-D	Mô tả dữ liệu	13
IV-E	Chiến lược vượt qua cơ chế bảo mật (Anti-Scraping Evasion)	14
IV-E1	Mô phỏng hành vi người dùng (User Behavior Simulation)	14
IV-E2	Quản lý dấu vân tay trình duyệt (Browser Fingerprinting)	14
IV-F	Khung phương pháp phân tích dữ liệu (Analytical Framework)	14
IV-F1	Phân tích tương quan (Correlation Analysis)	14
IV-F2	Phân cụm dữ liệu (K-Means Clustering)	15
IV-G	Quy trình đảm bảo chất lượng dữ liệu (Data Quality Assurance)	15
V	Thực hiện và Cài đặt	18
V-A	Môi trường phát triển	18
V-A1	Cấu hình phần cứng	18
V-A2	Công cụ và Thư viện phần mềm	18
V-B	Chi tiết giải thuật và Mã nguồn	18
V-B1	Cơ chế khởi tạo và Quản lý Profile	19
V-B2	Kỹ thuật chờ đợi thông minh (Explicit Wait)	19
V-B3	Logic trích xuất và Xử lý ngoại lệ	19
V-B4	Cơ chế Anti-Ban và Cuộn trang	20
VI	Truy vấn và Khám phá dữ liệu trên MongoDB	21
VI-A	Truy vấn mẫu dữ liệu đầu tiên	21
VI-B	Sắp xếp theo Tỷ lệ tương tác (Engagement)	22
VI-C	Thống kê dữ liệu ẩn giá	22
VI-D	Tìm kiếm theo từ khóa (Regex)	23
VII	Kết quả và Phân tích dữ liệu	24
VII-A	Phân tích cấu trúc và Dữ liệu khuyết (Missing Values)	24
VII-B	Đặc điểm phân phối của các chỉ số hiệu suất chính (KPIs)	25
VII-B1	Phân phối Lượng người theo dõi (Followers)	25
VII-B2	Phân phối Tỷ lệ tương tác (Engagement Rate)	25
VII-B3	Phân phối Điểm hợp tác (Collab Score)	25
VII-C	Phân tích hành vi tương tác theo Chủ đề nội dung (Content Analysis)	26
VII-D	Kiểm định đa cộng tuyến và Mối quan hệ giữa các biến	27
VII-E	Kiểm định giả thuyết: Sự minh bạch giá và Quy mô tài khoản	28
VIII	Kiểm thử và Đánh giá hệ thống	29
VIII-A	Xây dựng Kịch bản kiểm thử (Test Cases)	29
VIII-A1	Kiểm thử chức năng Khởi tạo và Đăng nhập	29
VIII-A2	Kiểm thử chức năng Thu thập dữ liệu	29
VIII-A3	Kiểm thử chức năng Chống chặn (Anti-Ban)	29
VIII-B	Đánh giá Hiệu năng (Performance Evaluation)	30
IX	Thảo luận	31
IX-A	Sự "mờ đục" của thị trường và chiến lược định giá (Price Opacity)	31
IX-B	Nghịch lý về Nội dung: Giải trí thắng thế Chuyên môn	31
IX-C	Thách thức phi tuyến tính trong việc dự báo giá trị	31

X	Kết luận và Kiến nghị	33
X-A	Kết luận chung	33
X-B	Kiến nghị và Hướng phát triển	33
X-B1	Về mặt Kỹ thuật và Khoa học dữ liệu	33
X-B2	Về mặt Chiến lược Nội dung và Marketing	33

Phụ lục A: Mã nguồn chương trình (Source Code)	35
---	-----------

Phụ lục B: Mẫu dữ liệu JSON	38
------------------------------------	-----------

Tài liệu tham khảo	39
---------------------------	-----------

Phụ lục C: Phân công công việc và Đóng góp thành viên		40
C-A	Tổng hợp phân công nhiệm vụ	40
C-B	Mình chứng đóng góp và Hoạt động chi tiết	40
C-B1	Thành viên: Đoàn Phú - Phụ trách Xử lý dữ liệu và Cấu hình	40
C-B2	Thành viên: Lâm Trần Tấn Phát - Phụ trách Core Backend	41
C-B3	Thành viên: Đỗ Quốc Khánh - Phụ trách QA và Tích hợp	41

DANH SÁCH HÌNH ẢNH

1	Sơ đồ kiến trúc phần mềm 3 tầng của hệ thống	9
2	Sơ đồ quy trình thu thập và xử lý dữ liệu (Pipeline)	10
3	Quy trình kiểm soát chất lượng dữ liệu	16
4	Kết quả truy vấn 20 bản ghi đầu tiên	21
5	Top 20 nhà sáng tạo có tỷ lệ tương tác cao nhất	22
6	Kết quả đếm số lượng nhà sáng tạo không công khai giá	22
7	Tìm kiếm các tài khoản có tên chứa từ khóa "Official"	23
8	Tỷ lệ phần trăm giá trị khuyết trên từng thuộc tính	24
9	Phân phối xác suất của Followers, Engagement Rate và Collab Score	25
10	So sánh mức độ phân tán Tỷ lệ tương tác theo Top 10 Chủ đề	26
11	Ma trận hệ số tương quan nhiệt (Correlation Heatmap)	27
12	Phân tích so sánh lượng Follower theo trạng thái công khai giá	28
13	Các commit liên quan đến cập nhật cấu trúc	41
14	Lịch sử xử lý Cookies và làm sạch Tags	41
15	Commit log của module Crawler và Scroll	41
16	Hiện thực hóa kết nối MongoDB và tải ảnh	41
17	Lịch sử Review code và Merge nhánh	41
18	Các commit chuẩn hóa dữ liệu cuối cùng	41

DANH SÁCH BẢNG

I	So sánh các công cụ Web Scraping phổ biến	6
II	Đặc tả Use Case: Thu thập dữ liệu	8
III	Từ điển dữ liệu cho Collection creators	8
IV	Cấu hình phân cứng máy trạm	18
V	Danh sách các công cụ và thư viện sử dụng	18
VI	Test Case: Khởi tạo hệ thống	29
VII	Test Case: Thu thập dữ liệu	29
VIII	Test Case: Cơ chế Anti-Ban	29
IX	Kết quả đo lường hiệu năng	30
X	Bảng phân công nhiệm vụ chi tiết và vai trò kỹ thuật	40

DANH MỤC CÁC KÝ HIỆU VÀ CHỮ VIẾT TẮT

Ký hiệu/Viết tắt	Diễn giải
AJAX	Asynchronous JavaScript and XML (Kỹ thuật tạo web động bất đồng bộ)
API	Application Programming Interface (Giao diện lập trình ứng dụng)
BSON	Binary JSON (Định dạng lưu trữ nhị phân của JSON dùng trong MongoDB)
CSS	Cascading Style Sheets (Ngôn ngữ định dạng kiểu cho tài liệu HTML)
CSR	Client-Side Rendering (Kỹ thuật kết xuất nội dung phía máy khách)
DOM	Document Object Model (Mô hình đối tượng tài liệu)
EDA	Exploratory Data Analysis (Phân tích dữ liệu khám phá)
ETL	Extract - Transform - Load (Quy trình Trích xuất - Chuyển đổi - Tải dữ liệu)
HTML	HyperText Markup Language (Ngôn ngữ đánh dấu siêu văn bản)
JSON	JavaScript Object Notation (Định dạng trao đổi dữ liệu dạng văn bản)
KOC	Key Opinion Consumer (Người tiêu dùng có sức ảnh hưởng chủ chốt)
KOL	Key Opinion Leader (Người dẫn dắt dư luận/Người có sức ảnh hưởng)
KPI	Key Performance Indicator (Chỉ số đo lường hiệu quả công việc)
NoSQL	Not Only SQL (Cơ sở dữ liệu phi quan hệ)
RDBMS	Relational Database Management System (Hệ quản trị cơ sở dữ liệu quan hệ)
SPA	Single Page Application (Ứng dụng web trang đơn)
SSR	Server-Side Rendering (Kỹ thuật kết xuất nội dung phía máy chủ)
TCM	TikTok Creator Marketplace (Sàn giao dịch nhà sáng tạo TikTok)
UML	Unified Modeling Language (Ngôn ngữ mô hình hóa thống nhất)
URL	Uniform Resource Locator (Định vị tài nguyên thống nhất - Đường dẫn web)
XPath	XML Path Language (Ngôn ngữ truy vấn vị trí các phần tử trong XML/HTML)

Thu thập dữ liệu thông tin các nhà sáng tạo nội dung trên Tiktok từ website TiktokOne bằng Selenium và MongoDB

1st Do Quoc Khanh, 2nd Doan Phu, 3rd Lam Tran Tan Phat và Le Nhat Tung
HUTECH University, Vietnam
{phudoan161, dqk2210, lamphat.344961}@gmail.com and lenhattung@hutech.edu.vn

Tóm tắt nội dung

Hiện nay, nhu cầu khai thác dữ liệu để tối ưu hóa chiến dịch Influencer Marketing đang trở nên cấp thiết hơn bao giờ hết [1], [2]. Để giải quyết vấn đề thu thập dữ liệu lớn từ nền tảng TikTokOne, đề tài “Thu thập thông tin của các nhà sáng tạo nội dung trên TikTok trên nền tảng TikTokOne bằng công cụ Selenium và MongoDB” được triển khai nhằm ứng dụng sức mạnh của các công cụ tự động hóa [3].

Bằng cách kết hợp khả năng thu thập dữ liệu động của Selenium [4] và khả năng lưu trữ linh hoạt của MongoDB [5], hệ thống cho phép trích xuất nhanh chóng các thông số chi tiết của nhà sáng tạo nội dung. Nguồn dữ liệu này đóng vai trò nền tảng cho việc phân tích xu hướng (EDA) [6], giúp các nhà nghiên cứu và doanh nghiệp đánh giá chính xác hiệu quả tiềm năng và đưa ra các lựa chọn hợp tác dựa trên dữ liệu thực tế [7].

Từ khóa

TiktokOne; Selenium; MongoDB; Web Scraping (Thu thập dữ liệu web); Data Analysis (Phân tích dữ liệu); Content Creator.

I. GIỚI THIỆU

A. TikTok

Trong thập kỷ qua, bối cảnh truyền thông xã hội đã chứng kiến sự chuyển dịch mạnh mẽ từ nội dung văn bản và hình ảnh sang định dạng video ngắn (short-form video). TikTok, nền tảng video âm nhạc và mạng xã hội đến từ Trung Quốc, đứng đầu làn sóng này và đã chứng kiến sự tăng trưởng thần tốc trên toàn cầu, thay đổi hoàn toàn cách người dùng tiêu thụ nội dung số [2].

Không dừng lại ở một ứng dụng giải trí thuần túy, TikTok đã phát triển thành một hệ sinh thái "Shoppertainment" (mua sắm kết hợp giải trí) đầy quyền năng. Tại đây, các xu hướng (trends) không chỉ được hình thành mà còn lan truyền với tốc độ chóng mặt nhờ thuật toán gợi ý nội dung (recommendation algorithm) siêu cá nhân hóa. Đối với các nhãn hàng, TikTok hiện được xem là "mỏ vàng" để tiếp cận thế hệ Gen Z và Millennials—nhóm khách hàng ngày càng hoài nghi với quảng cáo truyền thống nhưng lại đặt niềm tin lớn vào các Influencer (người có sức ảnh hưởng) [8]. Do đó, việc nắm bắt thông tin sâu sát về hệ sinh thái TikTok, đặc biệt là dữ liệu về các nhà sáng tạo nội dung, là cơ sở cốt lõi để xây dựng các chiến lược quảng bá hiệu quả và tối ưu hóa chi phí Marketing [1].

B. TikTokOne (Creator Marketplace)

TikTokOne, hay còn được biết đến với tên gọi TikTok Creator Marketplace (TCM), là nền tảng chính thức và duy nhất do TikTok cung cấp để làm cầu nối minh bạch giữa thương hiệu (Brands) và các nhà sáng tạo nội dung (Creators). Khác với các công cụ phân tích bên thứ ba thường dựa vào ước tính, TCM chứa đựng nguồn dữ liệu "first-party" (dữ liệu bên thứ nhất) xác thực và chi tiết nhất.

Nền tảng này cung cấp hồ sơ năng lực toàn diện của các KOLs/KOCs, bao gồm các chỉ số chuyên sâu như phân bố nhân khẩu học của người theo dõi (độ tuổi, giới tính, vị trí địa lý), biểu đồ tăng trưởng, tỷ lệ tương tác (engagement rate), và khung chi phí hợp tác tham khảo. Tuy nhiên, rào cản lớn nhất đối với các nhà nghiên cứu và doanh nghiệp là TCM không cung cấp API công khai (Public API) cho việc trích

xuất dữ liệu quy mô lớn. Việc truy cập và tổng hợp dữ liệu thủ công (manual entry) gặp nhiều hạn chế nghiêm trọng về thời gian, dễ sai sót và không thể cập nhật theo thời gian thực (real-time), đặt ra nhu cầu cấp thiết về một giải pháp tự động hóa thông minh [3].

C. Selenium

Trong bối cảnh các trang web hiện đại ngày càng phức tạp, các phương pháp thu thập dữ liệu truyền thống (như thư viện `requests` hay `BeautifulSoup`) thường trở nên vô hiệu. Nguyên nhân là do các nền tảng như TikTokOne sử dụng kiến trúc Single Page Application (SPA) và tải nội dung động thông qua JavaScript (Client-side rendering) [3]. Dữ liệu không nằm sẵn trong mã nguồn HTML tĩnh mà được tải về bất đồng bộ (asynchronous) khi người dùng tương tác.

Selenium nổi lên là giải pháp tối ưu cho thách thức này. Vốn là một framework kiểm thử tự động mã nguồn mở mạnh mẽ [4], Selenium cho phép điều khiển trình duyệt web (như Chrome, Firefox) thông qua giao thức WebDriver. Khả năng đặc biệt của Selenium là giả lập hoàn hảo các thao tác của người dùng thật (human-like behaviors) như cuộn trang (infinite scroll) để kích hoạt tải dữ liệu, nhấp chuột vào các phần tử bị che khuất, và nhập liệu vào các biểu mẫu đăng nhập. Sự kết hợp giữa khả năng tương tác trực tiếp với DOM (Document Object Model) và sức mạnh xử lý của ngôn ngữ lập trình Python [9] khiến Selenium trở thành công cụ lý tưởng để vượt qua các rào cản kỹ thuật và thu thập dữ liệu trên các nền tảng phức tạp này.

D. MongoDB

Dữ liệu thu thập từ mạng xã hội nói chung và TikTok nói riêng thường có đặc điểm của dữ liệu lớn (Big Data): khối lượng lớn (Volume), tốc độ thay đổi nhanh (Velocity) và sự đa dạng cao (Variety). Thông tin của một Creator thường bao gồm các cấu trúc phân cấp phức tạp và không đồng nhất (ví dụ: danh sách tags sở trường, lịch sử các video viral, các chỉ số thay đổi theo thời gian). Các hệ quản trị cơ sở dữ liệu quan hệ (RDBMS) truyền thống như MySQL hay SQL Server với lược đồ (schema) cứng nhắc thường gặp khó khăn và kém hiệu quả khi xử lý loại dữ liệu này [7].

MongoDB, đại diện tiêu biểu của dòng cơ sở dữ liệu NoSQL hướng tài liệu (document-oriented), là mảnh ghép hoàn hảo cho bài toán này. Với cơ chế lưu trữ dữ liệu dưới dạng JSON/BSON (Binary JSON), MongoDB mang lại sự linh hoạt tối đa [5]. Nó cho phép lưu trữ trực tiếp các đối tượng dữ liệu phức tạp mà không cần chuẩn hóa khắt khe, đồng thời hỗ trợ khả năng mở rộng theo chiều ngang (horizontal scaling) dễ dàng. Điều này đảm bảo hệ thống có thể xử lý hàng nghìn bản ghi Creator với hiệu suất truy vấn cao, phục vụ tốt cho các tác vụ phân tích sau này.

E. Mục tiêu và Đóng góp của Nghiên cứu

Dựa trên cơ sở lý thuyết về tầm quan trọng của dữ liệu Influencer và các công cụ kỹ thuật hiện đại, đề tài tập trung giải quyết bài toán "khát dữ liệu" của thị trường thông qua các mục tiêu cụ thể sau:

- **Xây dựng quy trình thu thập dữ liệu tự động (Automated Data Pipeline):** Thiết kế và phát triển công cụ (Bot) sử dụng Selenium để tự động hóa toàn bộ quy trình: từ đăng nhập bảo mật, điều hướng thông minh qua các danh sách Creator, đến việc trích xuất chính xác các trường thông tin chi tiết (Profile, Engagement, Pricing, Audience) trên TikTokOne mà không bị chặn bởi các cơ chế bảo mật.
- **Thiết kế kho lưu trữ dữ liệu hiệu quả và linh hoạt:** Triển khai kiến trúc cơ sở dữ liệu trên nền tảng **MongoDB** để tổ chức và lưu trữ dữ liệu theo một cách khoa học. Hệ thống lưu trữ cần đảm bảo tính toàn vẹn, giảm thiểu dư thừa và sẵn sàng cho việc truy xuất nhanh chóng phục vụ các ứng dụng phân tích [5].
- **Phân tích và trực quan hóa dữ liệu hỗ trợ ra quyết định:** Thực hiện các bước tiền xử lý (Data Cleaning) và Phân tích dữ liệu khám phá (EDA) [6] trên tập dữ liệu thu thập được. Mục tiêu cuối cùng là cung cấp các báo cáo trực quan (Dashboard) về xu hướng thị trường, giúp các nhân hàng

định lượng được giá trị thực của nhà sáng tạo, từ đó đưa ra các quyết định hợp tác (Booking) dựa trên dữ liệu thực tế (Data-driven decision making) thay vì cảm tính.

II. CƠ SỞ LÝ THUYẾT

Chương này trình bày hệ thống các cơ sở lý thuyết nền tảng được sử dụng trong nghiên cứu. Nội dung bao gồm sự phân tích chuyên sâu về Influencer Marketing dưới góc độ dữ liệu, cơ chế thuật toán của TikTok, các nguyên lý kỹ thuật trong trích xuất thông tin web (Web Scraping) và kiến trúc cơ sở dữ liệu phi quan hệ (NoSQL) phục vụ lưu trữ dữ liệu lớn.

A. Tổng quan về Influencer Marketing

1) *Định nghĩa và Sự chuyển dịch mô hình:* Influencer Marketing (Tiếp thị qua người ảnh hưởng) là một hình thức tiếp thị truyền thông xã hội liên quan đến sự chứng thực và vị trí sản phẩm từ những người có ảnh hưởng, những người sở hữu kiến thức chuyên môn hoặc tác động xã hội trong lĩnh vực của họ [8].

Trong bối cảnh người tiêu dùng ngày càng trở nên "mù quảng cáo" (banner blindness) và mất niềm tin vào các hình thức quảng cáo truyền thống, Influencer đóng vai trò là "người dẫn dắt quan điểm" (Key Opinion Leader - KOL). Theo mô hình truyền thông hai bước (Two-step flow of communication), thông tin từ phương tiện truyền thông đại chúng không đến trực tiếp người tiêu dùng mà đi qua các thủ lĩnh ý kiến (Opinion Leaders). Họ xây dựng niềm tin với khán giả thông qua nội dung chân thực (Authenticity) và tương tác hai chiều (Para-social interaction).

Theo báo cáo của [1], ngành công nghiệp này đã phát triển từ một chiến thuật phụ trợ thành một kênh tiếp thị thiết yếu, đặc biệt hiệu quả trong việc tiếp cận thế hệ Gen Z và Millennials, với quy mô thị trường ước tính đạt 21.1 tỷ USD vào năm 2023.

2) *Phân loại Influencer theo Dữ liệu:* Việc phân loại Influencer không chỉ dựa trên cảm tính mà dựa trên các ngưỡng dữ liệu (Data thresholds) cụ thể về lượng người theo dõi (Followers). Sự phân loại này quyết định chiến lược thu thập và lấy mẫu dữ liệu trong đồ án:

- **Nano-Influencer (1K - 10K followers):** Thường là những người dùng bình thường chia sẻ về sở thích cá nhân. Tuy phạm vi tiếp cận thấp, nhưng họ có tỷ lệ tương tác cao nhất và chi phí thấp nhất. Đây là nhóm dữ liệu "Long-tail" quan trọng cần khai thác.
- **Micro-Influencer (10K - 100K followers):** Đây là nhóm chiếm tỷ trọng lớn nhất trên thị trường. Họ thường tập trung vào một thị trường ngách (niche market) cụ thể như làm đẹp, công nghệ, hoặc giáo dục. Các nghiên cứu chỉ ra rằng đây là nhóm mang lại ROI (Return on Investment) tốt nhất nhờ sự cân bằng giữa độ phủ và độ tin cậy [2].
- **Macro-Influencer (100K - 1M followers):** Thường là các nhà sáng tạo nội dung chuyên nghiệp (Content Creators), Blogger hoặc Youtuber. Họ có khả năng tạo ra xu hướng (trendsetter) nhưng tỷ lệ tương tác thường thấp hơn nhóm Micro do tệp fan đã loãng.
- **Mega-Influencer (> 1M followers):** Là các ngôi sao hạng A, người nổi tiếng. Họ có độ phủ sóng cực lớn, phù hợp cho các chiến dịch nhận diện thương hiệu (Brand Awareness) nhưng chi phí hợp tác rất cao và khó tiếp cận dữ liệu chính xác nếu không qua nền tảng chính thức.

3) *Các chỉ số đo lường hiệu quả (KPIs):* Để đánh giá một Influencer, nghiên cứu sử dụng các công thức toán học định lượng sau:

- **Engagement Rate (ER):** Tỷ lệ tương tác, phản ánh chất lượng nội dung. Có nhiều cách tính, nhưng phổ biến nhất là:

$$ER = \frac{\text{Total Likes} + \text{Total Comments} + \text{Total Shares}}{\text{Total Views}} \times 100\% \quad (1)$$

- **Growth Rate:** Tốc độ tăng trưởng người theo dõi theo thời gian:

$$GR = \frac{\text{Followers}_{\text{current}} - \text{Followers}_{\text{previous}}}{\text{Followers}_{\text{previous}}} \times 100\% \quad (2)$$

- **CPV (Cost Per View):** Chi phí trên mỗi lượt xem, giúp nhãn hàng ước lượng ngân sách:

$$CPV = \frac{\text{Booking Price}}{\text{Median Views}} \quad (3)$$

B. Hệ sinh thái TikTok và Social Commerce

1) **Mô hình Shoppertainment:** TikTok không chỉ là một mạng xã hội video mà còn là người tiên phong trong mô hình "Shoppertainment" sự kết hợp giữa mua sắm (Shopping) và giải trí (Entertainment). Khác với thương mại điện tử truyền thống nơi người dùng tìm kiếm sản phẩm theo nhu cầu (Search-based), TikTok kích thích nhu cầu tiềm ẩn thông qua nội dung video hấp dẫn (Discovery-based). Điều này đặt ra yêu cầu cấp thiết về việc phân tích dữ liệu content để hiểu được yếu tố nào thúc đẩy hành vi mua hàng.

2) **Thuật toán phân phối: Interest Graph:** Sự thành công của TikTok đến từ thuật toán gợi ý nội dung dựa trên "Biểu đồ sở thích"(Interest Graph) thay vì "Biểu đồ xã hội"(Social Graph) như Facebook.

- **Social Graph:** Nội dung được phân phối dựa trên mối quan hệ bạn bè (ai follow ai). Mạng lưới bị giới hạn bởi connection.
- **Interest Graph:** Nội dung được phân phối dựa trên hành vi tương tác (thời gian xem, like, share) đối với từng loại nội dung cụ thể.

3) **Cơ chế Lưu lượng (Traffic Pool Mechanism):** Hệ thống đề xuất của TikTok hoạt động theo cơ chế "Traffic Pool" phân tầng:

- 1) **Cold Start:** Video mới đăng được phân phối cho 200-500 người dùng ngẫu nhiên.
- 2) **Evaluation:** Hệ thống đo lường các chỉ số: Tỷ lệ hoàn thành video (Completion Rate), Like, Comment, Share.
- 3) **Amplification:** Nếu chỉ số tốt, video được đẩy lên các bể lưu lượng lớn hơn (1K, 10K, 100K view).
- 4) **Trending:** Video đạt ngưỡng lan truyền sẽ được đưa vào tab "For You"(Dành cho bạn).

Cơ chế này cho phép một tài khoản mới lập vẫn có thể tạo ra video triệu view. Đây chính là lý do tại sao việc thu thập dữ liệu về *Median View* và *Engagement* quan trọng hơn chỉ số *Followers* đơn thuần.

C. Cơ sở lý thuyết về Web Scraping

1) **Kiến trúc Website hiện đại và DOM:** Web Scraping là kỹ thuật trích xuất dữ liệu từ các trang web. Để thực hiện điều này, cần hiểu rõ kiến trúc Document Object Model (DOM). DOM là một giao diện lập trình ứng dụng (API) cho các tài liệu HTML và XML. Nó định nghĩa cấu trúc logic của tài liệu và cách thức truy cập và thao tác.

Đối với các website hiện đại như TikTokOne:

- 1) **Server-Side Rendering (SSR):** HTML được tạo hoàn chỉnh từ server. Dễ cài nhưng ít được dùng cho web app phức tạp.
- 2) **Client-Side Rendering (CSR):** Máy chủ chỉ gửi khung HTML rỗng. Trình duyệt tải JavaScript về và gọi API để hiển thị dữ liệu (Single Page Application - SPA). TikTokOne sử dụng CSR, do đó nếu dùng thư viện `requests` thông thường sẽ chỉ nhận được trang trắng.
- 2) **Kỹ thuật định vị phần tử (Element Locators):** Để Selenium có thể tương tác với web, ta cần xác định vị trí các phần tử trong DOM Tree. Hai kỹ thuật chính được sử dụng trong đó là:
 - **XPath (XML Path Language):** Ngôn ngữ truy vấn để chọn các nút trong tài liệu XML/HTML. XPath cho phép điều hướng hai chiều (lên cha, xuống con). Ví dụ: `//div[@class='info']//span[contains(`
 - **CSS Selectors:** Sử dụng cú pháp của CSS để chọn phần tử. Nhanh hơn XPath nhưng không hỗ trợ tìm kiếm theo nội dung văn bản (text content). Ví dụ: `div.info > span.follower-count`

3) So sánh các công cụ thu thập dữ liệu: Bảng dưới đây biện giải lý do lựa chọn Selenium thay vì các công cụ khác [3]:

Bảng I
SO SÁNH CÁC CÔNG CỤ WEB SCRAPING PHỔ BIẾN

Tiêu chí	Requests / BeautifulSoup	Selenium	Scrapy
Loại hình	Thư viện HTTP	Công cụ tự động hóa trình duyệt	Framework thu thập dữ liệu
Xử lý JavaScript	Không hỗ trợ	Hỗ trợ tốt (Render đầy đủ DOM)	Hỗ trợ hạn chế
Tương tác	Không thể click/scroll	Giả lập hành vi người dùng (Click, Scroll)	Không hỗ trợ
Tốc độ	Rất nhanh	Chậm (do tải UI)	Nhanh
Ứng dụng	Web tĩnh	Web động (SPA), TikTok	Web tĩnh quy mô lớn

4) *Khía cạnh Đạo đức và Pháp lý*: Trong nghiên cứu thu thập dữ liệu, vấn đề đạo đức (Ethics) và tuân thủ quy định là tối quan trọng:

- **Robots.txt**: Đây là file tiêu chuẩn để website chỉ định cho bot biết được phép cào trang nào. Cần kiểm tra file này trước khi thực hiện.
- **Rate Limiting**: Việc gửi quá nhiều request trong thời gian ngắn có thể bị coi là tấn công DoS. Đồ án áp dụng cơ chế *Random Sleep* để tôn trọng băng thông của máy chủ đích.
- **Dữ liệu cá nhân (PII)**: Chỉ thu thập các dữ liệu công khai (Publicly Available Data) dành cho mục đích kinh doanh (Business Profiles), tuân thủ các quy định về quyền riêng tư như GDPR (nếu áp dụng).

D. Cơ sở dữ liệu NoSQL và MongoDB

1) *Định lý CAP và Hạn chế của RDBMS*: Trong kỷ nguyên Big Data, các hệ quản trị cơ sở dữ liệu quan hệ (RDBMS) như MySQL bộc lộ hạn chế về khả năng mở rộng (Scalability) và tính linh hoạt. Định lý CAP phát biểu rằng một hệ thống phân tán không thể đồng thời đảm bảo cả ba tính chất:

- **C (Consistency)**: Tính nhất quán dữ liệu ở mọi node.
- **A (Availability)**: Tính sẵn sàng hoạt động mọi lúc.
- **P (Partition Tolerance)**: Khả năng chịu lỗi khi mất kết nối mạng.

MongoDB là CSDL NoSQL ưu tiên AP hoặc CP, hỗ trợ Sharding (phân mảnh dữ liệu) giúp mở rộng theo chiều ngang (Horizontal Scaling) dễ dàng trên các cụm máy chủ giá rẻ.

2) *Mô hình dữ liệu hướng tài liệu (Document-Oriented)*: MongoDB lưu trữ dữ liệu dưới dạng BSON (Binary JSON). Đặc điểm này phù hợp tuyệt đối với dữ liệu mạng xã hội:

- **Schema-less (Không lược đồ)**: Không cần định nghĩa trước cấu trúc bảng. Mỗi Creator có thể có các trường khác nhau (ví dụ: người có Email, người không).
- **Embedded Documents (Tài liệu nhúng)**: Dữ liệu liên quan được lồng vào nhau thay vì tách bảng và JOIN. Ví dụ:

Ví dụ cấu trúc dữ liệu Creator trong MongoDB:

```
{
  "_id": "user_123",
  "name": "TikTok Creator",
  "stats": {
    "followers": 1500000,
    "likes": 20000000
  }
}
```

```
},
"tags": ["Fashion", "Lifestyle"],
"history": [
  {"date": "2023-10-01", "views": 50000}
]
}
```

3) *Cơ chế Đánh chỉ mục (Indexing)*: Để tối ưu hóa truy vấn trên tập dữ liệu lớn (hàng chục nghìn bản ghi), MongoDB sử dụng cấu trúc B-Tree cho Index. Trong đồ án này, trường `_id` được đánh index mặc định để đảm bảo tính duy nhất và tốc độ kiểm tra trùng lặp (duplication check) đạt độ phức tạp $O(\log N)$. Ngoài ra, Index cũng được tạo trên các trường `Followers` và `Tags` để phục vụ các truy vấn lọc nhanh chóng.

4) *Aggregation Framework*: MongoDB cung cấp Aggregation Framework mạnh mẽ để xử lý dữ liệu ngay trong database (Server-side processing). Các toán tử như `$match`, `$group`, `$project` cho phép thực hiện các thống kê phức tạp (ví dụ: Tính trung bình Engagement theo từng nhóm Tags) mà không cần tải toàn bộ dữ liệu về ứng dụng Python để xử lý, giúp tiết kiệm băng thông và bộ nhớ RAM.

III. PHÂN TÍCH VÀ THIẾT KẾ HỆ THỐNG

Chương này tập trung vào việc phân tích các yêu cầu nghiệp vụ và kỹ thuật của hệ thống, từ đó xây dựng các mô hình thiết kế chi tiết bao gồm biểu đồ Use Case, biểu đồ Tuần tự và thiết kế cơ sở dữ liệu.

A. Phân tích yêu cầu

1) *Yêu cầu chức năng*: Hệ thống cần đáp ứng các nhóm chức năng chính sau:

- **Chức năng Cấu hình**: Cho phép người dùng thiết lập các tham số đầu vào như đường dẫn Profile Firefox, số lượng mẫu cần thu thập.
- **Chức năng Thu thập (Crawling)**: Tự động truy cập website, vượt qua màn hình đăng nhập và trích xuất dữ liệu.
- **Chức năng Lưu trữ**: Dữ liệu văn bản lưu vào MongoDB, hình ảnh lưu vào thư mục cục bộ.
- **Chức năng Báo cáo/Log**: Hiển thị trạng thái hoạt động của Bot theo thời gian thực.

2) *Yêu cầu phi chức năng*:

- **Hiệu năng**: Hoạt động liên tục trên 2 giờ.
- **Anti-ban**: Tích hợp cơ chế giả lập hành vi người dùng.
- **Tính tin cậy**: Cơ chế xử lý lỗi chặt chẽ.

B. Mô hình hóa hệ thống (UML)

1) *Đặc tả Use Case Thu thập dữ liệu*: Bảng dưới đây mô tả chi tiết kịch bản hoạt động:

Bảng II
ĐẶC TẢ USE CASE: THU THẬP DỮ LIỆU

Tên Use Case	Start Crawling (Thu thập dữ liệu)
Tác nhân	Quản trị viên (Admin)
Mô tả	Bot tự động mở trình duyệt và thu thập thông tin Creator.
Tiền điều kiện	• MongoDB đã bật. • Config hợp lệ.
Luồng sự kiện	1) Admin kích hoạt Bot. 2) Hệ thống mở Firefox. 3) Hệ thống vào TikTok Marketplace. 4) Hệ thống quét và lưu dữ liệu.
Ngoại lệ	Mất mạng hoặc Bị chặn.

C. Thiết kế Cơ sở dữ liệu


1) *Chi tiết cấu trúc Document*: Bảng dưới đây mô tả chi tiết các trường dữ liệu:

Bảng III
TỪ ĐIỂN DỮ LIỆU CHO COLLECTION CREATORS

Tên trường	Kiểu	Mô tả
_id	String	Khóa chính (VD: tranthanh).
Name	String	Tên hiển thị.
Followers	String	Số lượng người theo dõi.
Engagement	Float	Tỷ lệ tương tác.
Price	String	Giá booking.
Tags	Array	Danh sách nhãn chủ đề.
Median_Views	Int	Lượt xem trung bình.
Country	String	Quốc gia hoạt động.
Collab Score	Float	Điểm đánh giá hợp tác.

D. Thiết kế Kiến trúc phần mềm

Để đảm bảo tính mô-đun hóa, dễ dàng bảo trì và mở rộng trong tương lai, hệ thống phần mềm được thiết kế theo mô hình kiến trúc 3 tầng (Three-Tier Architecture). Mô hình này tách biệt rõ ràng giữa giao diện người dùng, logic nghiệp vụ và việc truy xuất dữ liệu.



Hình 1. Sơ đồ kiến trúc phần mềm 3 tầng của hệ thống

Chi tiết chức năng của từng tầng như sau:

1) 1. *Tầng Giao diện (Presentation Layer)*: Đây là tầng tương tác trực tiếp với người quản trị (Admin). Do đặc thù là một ứng dụng chạy nền (backend service), giao diện chính không phải là đồ họa (GUI) mà là giao diện dòng lệnh (CLI - Command Line Interface).

- **CLI Console**: Hiển thị tiến độ thu thập theo thời gian thực (ví dụ: số lượng Creator đã thu thập, tốc độ xử lý).
- **Logging System**: Ghi nhận và hiển thị các thông báo lỗi (Exceptions), cảnh báo (Warnings) khi bị chặn, giúp người quản trị giám sát sức khỏe của hệ thống.

2) 2. *Tầng Nghiệp vụ (Business Logic Layer)*: Đây là "bộ não" của hệ thống, nơi chứa toàn bộ các quy tắc xử lý chính. Tầng này không quan tâm dữ liệu hiển thị ra sao hay lưu trữ thế nào, mà chỉ tập trung vào logic xử lý.

- **Bot Engine**: Luồng điều khiển chính, chịu trách nhiệm khởi tạo trình duyệt, điều hướng URL và quản lý vòng lặp thu thập.
- **Anti-Ban Logic**: Chứa các thuật toán tạm dừng ngẫu nhiên, cuộn trang mô phỏng người dùng để vượt qua cơ chế bảo mật của TikTok.
- **Data Parser & Cleaner**: Trích xuất dữ liệu thô từ HTML và thực hiện các bước chuẩn hóa (như đã mô tả trong thuật toán tiền xử lý).

3) 3. *Tầng Truy cập Dữ liệu (Data Access Layer - DAL)*: Tầng này đóng vai trò là lớp trung gian trừu tượng hóa việc giao tiếp với nơi lưu trữ. Nó cung cấp các phương thức thống nhất để tầng nghiệp vụ gọi đến (ví dụ: `save_creator()`, `check_exists()`) mà không cần biết chi tiết kỹ thuật bên dưới.

- **PyMongo Driver**: Sử dụng thư viện `pymongo` để thiết lập kết nối, thực thi các truy vấn (Query) và lệnh cập nhật (Update/Insert) vào cơ sở dữ liệu MongoDB.
- **File Manager**: Quản lý việc tải xuống hình ảnh từ URL và lưu trữ vào thư mục cục bộ trên máy chủ, đảm bảo đặt tên file không bị trùng lặp.


IV. PHƯƠNG PHÁP NGHIÊN CỨU

A. Kiến trúc hệ thống

Để giải quyết bài toán thu thập và quản lý dữ liệu lớn từ nền tảng TikTokOne, nghiên cứu này đề xuất và áp dụng kiến trúc đường ống dữ liệu (Data Pipeline) dựa trên quy trình ETL (Extract - Transform - Load). Quy trình này được tự động hóa hoàn toàn nhằm đảm bảo tính liên tục và độ tin cậy của bộ dữ liệu về các nhà sáng tạo nội dung (Content Creators) [7].

Kiến trúc tổng thể bao gồm ba thành phần chính tương tác chặt chẽ với nhau:

- 1) **Module Thu thập (Extractor):** Sử dụng Selenium Bot hoạt động như một trình duyệt không đầu (hoặc có giao diện) để tương tác trực tiếp với website thông qua giao thức WebDriver. Thành phần này chịu trách nhiệm vượt qua các rào cản kỹ thuật của phía máy khách (Client-side) như tải trang động (AJAX) và cơ chế xác thực.
- 2) **Module Xử lý (Transformer):** Thực hiện chuẩn hóa dữ liệu ngay tại thời gian thực hoặc hậu kỳ, chuyển đổi dữ liệu thô dạng văn bản sang các định dạng số học có ý nghĩa thống kê.
- 3) **Module Lưu trữ (Loader):** Sử dụng MongoDB, một hệ quản trị cơ sở dữ liệu NoSQL hướng tài liệu (Document-oriented). Lựa chọn này xuất phát từ bản chất phi cấu trúc và đa dạng của dữ liệu mạng xã hội, cho phép lưu trữ linh hoạt các trường thông tin phân cấp (như danh sách Tags, lịch sử video) mà không cần định nghĩa lược đồ (Schema) cứng nhắc từ trước.



Hình 2. Sơ đồ quy trình thu thập và xử lý dữ liệu (Pipeline)

B. Quy trình thu thập dữ liệu (Crawling)

Quy trình thu thập dữ liệu là trái tim của hệ thống, được thực hiện bởi Selenium Bot được thiết kế tùy chỉnh [4]. Khác với các phương pháp gửi HTTP Request tĩnh truyền thống, Bot hoạt động bằng cách mô phỏng hành vi của một người dùng thật (Human-like behavior simulation). Điều này là tối quan trọng để tránh các cơ chế phát hiện Bot và chặn truy cập (anti-scraping) của nền tảng TikTok.

Chiến lược thu thập dữ liệu được chia thành các giai đoạn cụ thể như mô tả trong Thuật toán 1. Bot thực hiện một vòng lặp thông minh bao gồm các kỹ thuật:

- **Cuộn trang vô hạn (Infinite Scroll):** Do TikTokOne sử dụng kỹ thuật "Lazy Loading" (chỉ tải dữ liệu khi người dùng cuộn xuống), Bot được lập trình để cuộn trang xuống đáy, chờ dữ liệu tải qua API ngầm, và sau đó mới trích xuất thông tin.
- **Cơ chế chờ ngẫu nhiên (Randomized Wait):** Thay vì sử dụng các khoảng thời gian cố định, Bot áp dụng thời gian nghỉ ngẫu nhiên (Random sleep) giữa các hành động. Điều này giúp phá vỡ các mẫu hành vi máy móc (robot patterns) để bị phát hiện.
- **Quản lý phiên làm việc (Session Management):** Sử dụng Cookies của phiên đăng nhập hợp lệ để duy trì quyền truy cập mà không cần đăng nhập lại liên tục.

Quy trình này lặp lại cho đến khi đạt đủ số lượng mẫu mục tiêu ($N_{target} = 9000$), tuân thủ các nguyên tắc trích xuất dữ liệu web hiện đại được đề cập bởi Mitchell [3].

Algorithm 1 TikTok Creator Marketplace Crawler

1: **Input:** N_{target} (Mục tiêu), User Profile (Cookies)

2: **Output:** MongoDB collection chứa thông tin Creators [5]

3: **Phase 1: Khởi tạo (Initialization)**

4: Tắt các tiến trình duyệt cũ để giải phóng bộ nhớ

5: Khởi tạo WebDriver với profile chứa Cookies đăng nhập sẵn

6: Truy cập "TikTok Creator Marketplace"

7: Áp dụng bộ lọc: $Region \leftarrow "Vietnam"$

8: $S_{cache} \leftarrow$ Tải danh sách ID đã có từ MongoDB (tránh trùng lặp)

9: $count_{new} \leftarrow 0$, $count_{dup} \leftarrow 0$

10: **Phase 2: Vòng lặp thu thập (Scraping Loop)**

11: **while** $count_{new} < N_{target}$ **do**

12: **if** $count_{new} > 0$ **and** $count_{new} \pmod{100} = 0$ **then**

13: Nghỉ 60s; Cuộn trang ngẫu nhiên

▷ Cơ chế Anti-Ban

14: **end if**

15: $Rows \leftarrow$ Lấy danh sách thẻ HTML `div[data-index]` hiện có

16: **for all** row in $Rows$ **do**

17: $Cards \leftarrow$ Tìm các thẻ chứa thông tin creator trong row

18: **for all** $card$ in $Cards$ **do**

19: $id \leftarrow \text{GetCreatorID}(card)$

20: **if** $id \in S_{cache}$ **then**

21: $count_{dup} \leftarrow count_{dup} + 1$; **continue**

22: **else**

23: $info \leftarrow \text{ExtractFullDetails}(card)$

24: $\text{Database.Upsert}(info)$; $S_{cache}.Add(id)$

25: $count_{new} \leftarrow count_{new} + 1$

26: **end if**

27: **end for**

28: **end for**

29: **Phase 3: Điều hướng (Smart Navigation)**

30: $idx_{current} \leftarrow$ Chỉ số index lớn nhất của $Rows$

31: **if** Trang không tải thêm dữ liệu mới **then**

32: Scroll Up/Down mạnh để kích hoạt Lazy Load

33: Nếu thử lại > 15 lần thất bại $\rightarrow$ **Break**

34: **else**

35: Cuộn xuống phần tử cuối cùng

36: **end if**

37: Nghỉ ngẫu nhiên (2 – 3 giây)

38: **end while**

39: **return** "Crawling Completed"

C. Kỹ thuật tiền xử lý dữ liệu (Preprocessing)

Dữ liệu thô sau khi được trích xuất từ giao diện web (DOM elements) thường ở dạng chuỗi văn bản (String) chứa nhiều nhiễu và các ký tự đặc biệt, không phù hợp để tính toán trực tiếp. Ví dụ, các con số thường đi kèm đơn vị viết tắt (như "2.8M" cho 2.8 triệu, "1.200.000 VND") hoặc các ký tự phần trăm.

Để đảm bảo tính nhất quán và khả năng sử dụng cho các bước Phân tích dữ liệu khám phá (EDA) tiếp theo [6], chúng tôi phát triển bộ công cụ làm sạch dữ liệu sử dụng ngôn ngữ Python [9]. Các hàm trong Thuật toán 2 thực hiện các tác vụ chuyển đổi quan trọng:

- **Chuẩn hóa đơn vị số học:** Chuyển đổi các hậu tố "K"(nghìn), "M"(triệu) thành các số nguyên đầy đủ.

- **Làm sạch dữ liệu tiền tệ:** Loại bỏ ký hiệu tiền tệ ("VND", "\$") và các dấu phân cách hàng nghìn để chuyển về dạng số thực (Float).
- **Xử lý tỷ lệ phần trăm:** Chuyển đổi chuỗi phần trăm (ví dụ "5.5%") thành dạng thập phân (0.055) để phục vụ các phép toán thống kê.
- **Xử lý giá trị khuyết:** Các trường dữ liệu bị thiếu hoặc "N/A" được chuẩn hóa thành giá trị `null` để dễ dàng lọc hoặc điền khuyết sau này.

Algorithm 2 Các hàm làm sạch dữ liệu (Data Cleaning Functions)

```

1: Input: Giá trị thô  $x$  (String)
2: Output: Giá trị số thực (Float/Integer) đã chuẩn hóa

```

```

3: procedure CLEANSUFFIXNUMBER( $x$ )
4:   if  $x$  is null or  $x$  is "N/A" then return null
5:   end if
6:    $s \leftarrow \text{UpperCase}(x)$ 
7:    $s \leftarrow \text{Replace}(s, ',', '.')$ 
8:    $m \leftarrow 1$ 
9:   if  $s$  contains "M" then
10:     $m \leftarrow 1,000,000$ ;  $s \leftarrow \text{Remove}(s, "M")$ 
11:   else if  $s$  contains "K" then
12:     $m \leftarrow 1,000$ ;  $s \leftarrow \text{Remove}(s, "K")$ 
13:   end if
14:   return  $\text{ToFloat}(s) \times m$ 
15: end procedure

```

```

16: procedure CLEANCURRENCYVND( $x$ )
17:   if  $x$  is null then return null
18:   end if
19:    $s \leftarrow \text{String}(x)$ 
20:    $s \leftarrow \text{Remove}(s, " VND")$ 
21:    $s \leftarrow \text{Remove}(s, ",")$ 
22:   return  $\text{ToFloat}(s)$ 
23: end procedure

```

▷ Xóa dấu chấm ngàn

```

24: procedure CLEANPERCENTAGE( $x$ )
25:   if  $x$  is null then return null
26:   end if
27:    $s \leftarrow \text{String}(x)$ 
28:    $s \leftarrow \text{Replace}(s, ',', '.')$ 
29:    $s \leftarrow \text{Remove}(s, "\%")$ 
30:   return  $\text{ToFloat}(s)$ 
31: end procedure

```

D. Mô tả dữ liệu

Kết quả của quy trình thu thập và làm sạch là một bộ dữ liệu có cấu trúc (Structured Dataset) được lưu trữ dưới dạng JSON Schema trong MongoDB [5]. Mỗi bản ghi (Document) đại diện cho một hồ sơ nhà sáng tạo nội dung với đầy đủ các thuộc tính cần thiết để đánh giá hiệu quả Marketing. Các trường thông tin quan trọng bao gồm:

- **_id / ID (String):** Mã định danh duy nhất của Creator trên hệ thống TikTok, dùng làm khóa chính để truy vấn và loại bỏ trùng lặp.
- **Followers (Integer):** Tổng số lượng người theo dõi kênh. Đây là chỉ số cơ bản để phân loại quy mô Influencer (Nano, Micro, Macro, Mega).

- **Engagement Rate (Float):** Tỷ lệ tương tác trung bình (tổng like, share, comment chia cho tổng view hoặc follower). Chỉ số này phản ánh chất lượng nội dung và mức độ quan tâm của khán giả [1].
- **Start Price (Float):** Mức giá khởi điểm tham khảo cho một video quảng cáo (đơn vị VND). Trường dữ liệu này thường có tỷ lệ khuyết cao do tính chất thỏa thuận của thị trường.
- **Tags (Array):** Danh sách các nhãn phân loại chủ đề nội dung (ví dụ: Beauty, Gaming, Education), giúp nhãn hàng tìm kiếm Creator phù hợp với lĩnh vực sản phẩm.
- **Median View (Integer):** Số lượt xem trung bình của các video gần đây, phản ánh khả năng lan truyền (viral) thực tế tốt hơn so với tổng follower.
- **Country (String):** Quốc gia hoạt động chính, dùng để lọc thị trường mục tiêu.
- **Collab Score (Float):** Điểm số đánh giá mức độ uy tín và lịch sử hợp tác của Creator trên nền tảng.

E. Chiến lược vượt qua cơ chế bảo mật (Anti-Scraping Evasion)

Trong bối cảnh các nền tảng mạng xã hội như TikTok ngày càng thắt chặt các biện pháp bảo mật nhằm ngăn chặn việc thu thập dữ liệu tự động, nghiên cứu này đã phát triển một chiến lược đa lớp (Multi-layered Strategy) để đảm bảo tính liên tục của quá trình thu thập.

1) *Mô phỏng hành vi người dùng (User Behavior Simulation):* Các hệ thống phát hiện Bot (Bot Detection Systems) thường dựa trên việc phân tích các mẫu hành vi bất thường (Patterns). Để đối phó, Bot được lập trình để tuân theo các quy luật ngẫu nhiên thay vì tuyến tính:

- **Thời gian nghỉ ngẫu nhiên (Randomized Delays):** Thay vì sử dụng một khoảng thời gian chờ cố định Δt , hệ thống áp dụng phân phối chuẩn (Normal Distribution) cho thời gian nghỉ giữa các yêu cầu. Thời gian chờ T được xác định bởi công thức:

$$P(T) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{T-\mu}{\sigma}\right)^2} \quad (4)$$

Trong đó, kỳ vọng $\mu = 3s$ và độ lệch chuẩn $\sigma = 1s$. Cách tiếp cận này giúp các thao tác của Bot giống với tốc độ lướt web tự nhiên của con người [3].

- **Cuộn trang phi tuyến tính:** Hành vi cuộn chuột (Scroll) không thực hiện một mạch xuống cuối trang mà bao gồm các thao tác cuộn lên nhẹ (scroll up) và tạm dừng, mô phỏng việc người dùng đang đọc nội dung.

2) *Quản lý dấu vân tay trình duyệt (Browser Fingerprinting):* TikTok sử dụng kỹ thuật Browser Fingerprinting để nhận diện danh tính thiết bị thông qua các thông số như Canvas, WebGL, và AudioContext. Để giảm thiểu rủi ro bị phát hiện:

- 1) **Profile Persistence:** Sử dụng Profile Firefox thực tế thay vì Profile tạm thời. Điều này giúp giữ lại lịch sử duyệt web, cache và cookies, làm cho phiên làm việc trở nên "đáng tin cậy" hơn đối với máy chủ TikTok.
- 2) **Vô hiệu hóa Automation Flags:** Can thiệp vào biến môi trường của trình duyệt để ẩn cờ `navigator.webdriver`. Khi cờ này bật (giá trị `true`), các trang web dễ dàng nhận biết trình duyệt đang được điều khiển bởi Selenium.

F. Khung phương pháp phân tích dữ liệu (Analytical Framework)

Sau khi dữ liệu được làm sạch, nghiên cứu áp dụng các phương pháp thống kê và học máy không giám sát (Unsupervised Learning) để khai thác thông tin.

1) *Phân tích tương quan (Correlation Analysis):* Để xác định mối quan hệ giữa các biến số (ví dụ: Lượng người theo dõi và Tỷ lệ tương tác), chúng tôi sử dụng hệ số tương quan Pearson (r). Hệ số này đo lường mức độ tương quan tuyến tính giữa hai biến X và Y :

$$r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \sum (y_i - \bar{y})^2}} \quad (5)$$

Giá trị r nằm trong khoảng $[-1, 1]$, giúp xác định xem liệu việc tăng lượng người theo dõi có thực sự dẫn đến tăng tương tác hay không [6].


2) *Phân cụm dữ liệu (K-Means Clustering)*: Để phân loại các Influencer thành các nhóm có đặc điểm tương đồng (ví dụ: Nhóm hiệu quả cao, Nhóm tiềm năng), thuật toán phân cụm K-Means được sử dụng. Thuật toán này phân chia tập dữ liệu X thành K cụm rồi rạc C sao cho tổng bình phương khoảng cách từ các điểm dữ liệu đến tâm cụm (centroids) là nhỏ nhất:

$$J = \sum_{j=1}^K \sum_{i \in C_j} ||x_i - \mu_j||^2 \quad (6)$$

Trong đó μ_j là trung bình của các điểm dữ liệu trong cụm C_j . Phương pháp "Elbow Method" sẽ được áp dụng để xác định số lượng cụm K tối ưu.

G. Quy trình đảm bảo chất lượng dữ liệu (Data Quality Assurance)

Do dữ liệu thu thập từ Web thường chứa nhiễu (Noise), một quy trình kiểm soát chất lượng (QA) ba bước được thiết lập trước khi dữ liệu được đưa vào kho lưu trữ cuối cùng.



Hình 3. Quy trình kiểm soát chất lượng dữ liệu

- 1) **Kiểm tra tính duy nhất (Uniqueness):** Dựa trên trường khóa chính `_id`. Hệ thống tự động loại bỏ các bản ghi trùng lặp xảy ra do quá trình cuộn trang lặp lại nội dung cũ.
- 2) **Kiểm tra tính toàn vẹn (Completeness):** Các bản ghi thiếu các trường thông tin trọng yếu (Critical Fields) như `Followers` hoặc `Name` sẽ bị loại bỏ hoặc đánh dấu để xử lý riêng. Tỷ lệ dữ liệu khuyết cho phép (Threshold) được thiết lập là $< 5\%$.
- 3) **Kiểm tra tính hợp lệ (Validity):** Các ràng buộc logic (Constraints) được áp dụng:
 - $Followers \geq 0$
 - $0 \leq Engagement_Rate \leq 1$
 - $Price > 0$ (nếu có)

Bất kỳ dữ liệu ngoại lai (Outliers) vi phạm các quy tắc này sẽ được ghi log để kiểm tra thủ công.

V. THỰC HIỆN VÀ CÀI ĐẶT

Chương này trình bày chi tiết về quá trình hiện thực hóa giải pháp, từ việc thiết lập môi trường phát triển, cài đặt các thư viện phụ thuộc đến việc phân tích chi tiết các khối lệnh quan trọng. Đồng thời, kết quả thực nghiệm được minh họa qua các hình ảnh chụp màn hình thực tế trong quá trình hệ thống vận hành.

A. Môi trường phát triển

Để đảm bảo hệ thống hoạt động ổn định và có khả năng xử lý lượng dữ liệu lớn trong thời gian dài, việc cấu hình môi trường phần cứng và phần mềm là yếu tố tiên quyết.

1) *Cấu hình phần cứng*: Hệ thống được triển khai và kiểm thử trên máy trạm cá nhân với thông số kỹ thuật như sau. Việc sử dụng RAM dung lượng lớn (16GB) là cần thiết vì trình duyệt Firefox khi chạy automation tiêu tốn khá nhiều tài nguyên bộ nhớ.

Bảng IV
CẤU HÌNH PHẦN CỨNG MÁY TRẠM

Thành phần	Thông số	Ghi chú
CPU	Intel Core i5-11400H @ 2.70GHz	6 Cores, 12 Threads, đảm bảo xử lý đa nhiệm mượt mà.
RAM	16 GB DDR4	Đủ dung lượng để duy trì Selenium WebDriver và MongoDB Server chạy song song.
Ổ cứng	SSD 512 GB NVMe	Tốc độ đọc/ghi cao giúp việc lưu trữ ảnh và truy vấn DB nhanh chóng.
Mạng	Internet 100 Mbps	Bảng thông ổn định để tải ảnh và nội dung video.

2) *Công cụ và Thư viện phần mềm*: Dự án được phát triển dựa trên ngôn ngữ Python phiên bản 3.9. Các thư viện mã nguồn mở đóng vai trò nòng cốt trong kiến trúc hệ thống được liệt kê chi tiết dưới đây:

Bảng V
DANH SÁCH CÁC CÔNG CỤ VÀ THƯ VIỆN SỬ DỤNG

Thư viện/Công cụ	Phiên bản	Vai trò trong hệ thống
Python	3.9.x	Ngôn ngữ lập trình chính.
Selenium	4.10.0	Framework tự động hóa trình duyệt, điều khiển Firefox thực hiện các thao tác người dùng.
GeckoDriver	0.33.0	Trình điều khiển giao tiếp giữa Selenium và Firefox Browser.
PyMongo	4.5.0	Driver kết nối Python với cơ sở dữ liệu MongoDB.
Requests	2.31.0	Gửi HTTP Request để tải ảnh đại diện (Avatar) về máy.
Pandas	2.0.3	Thư viện xử lý và phân tích dữ liệu dạng bảng (Dataframe).
MongoDB Compass	1.40.4	Công cụ giao diện (GUI) để quản lý và trực quan hóa dữ liệu trong MongoDB.

B. Chi tiết giải thuật và Mã nguồn

Trong phần này, chúng tôi sẽ đi sâu phân tích logic của các module quan trọng nhất. Việc xây dựng Bot không chỉ đơn thuần là viết code chạy được, mà còn phải xử lý các bài toán về độ trễ mạng, thay đổi cấu trúc DOM và cơ chế chống Bot.

1) *Cơ chế khởi tạo và Quản lý Profile*: Một trong những thách thức lớn nhất khi cào dữ liệu từ TikTok là vấn đề đăng nhập và CAPTCHA. Thay vì cố gắng giải mã CAPTCHA (vốn rất phức tạp và tốn kém), chúng tôi sử dụng kỹ thuật "**Load Profile**".

```
1 options = webdriver.firefox.options.Options()
2 # Tro den Profile Firefox that của người dùng
3 options.add_argument("-profile")
4 options.add_argument(MY_PROFILE_PATH)
5
6 # Tat cac flag tu dong hoa de tranh bi phat hien
7 options.set_preference("dom.webdriver.enabled", False)
8 options.set_preference("useAutomationExtension", False)
9
10 driver = webdriver.Firefox(options=options, service=ser)
```

Listing 1. Cấu hình Firefox Profile để vượt qua đăng nhập

Giải thích:

- MY_PROFILE_PATH: Bằng cách trở Selenium vào thư mục Profile thực tế của người dùng (nơi đã lưu Cookies và Session đăng nhập TikTok), Bot sẽ khởi động với trạng thái "Đã đăng nhập". Điều này giúp bỏ qua hoàn toàn bước xác thực 2 lớp.
- dom.webdriver.enabled = False: Đây là một kỹ thuật "tàng hình"(Stealth). Thông thường, trình duyệt do Selenium điều khiển sẽ có biến navigator.webdriver = true. Các trang web như TikTok sẽ kiểm tra biến này để chặn Bot. Dòng lệnh này giúp ghi đè biến đó thành false, đánh lừa hệ thống bảo mật.

2) *Kỹ thuật chờ đợi thông minh (Explicit Wait)*: Trong lập trình automation, việc đồng bộ hóa giữa tốc độ code và tốc độ tải trang là cực kỳ quan trọng.

```
1 def safe_click(driver, xpath, retries=3):
2     for i in range(retries):
3         try:
4             # Cho doi toi da 3s de phan tu xuat hien trong DOM
5             element = WebDriverWait(driver, 3).until(
6                 EC.presence_of_element_located((By.XPATH, xpath))
7             )
8             # Cuon xuong de phan tu hien thi ro rang
9             driver.execute_script("arguments[0].scrollIntoView({block: 'center'});", element)
10            time.sleep(1)
11            driver.execute_script("arguments[0].click();", element)
12            return True
13        except:
14            time.sleep(1) # Cho them neu mang lag
15    return False
```

Listing 2. Sử dụng WebDriverWait thay vì time.sleep

Tại sao dùng WebDriverWait thay vì time.sleep?

- time.sleep(10): Là chờ đợi tĩnh (Static Wait). Chương trình sẽ dừng hẳn 10 giây bất kể trang web đã tải xong chưa. Nếu mạng nhanh, ta lãng phí thời gian. Nếu mạng chậm hơn 10s, code sẽ lỗi.
- WebDriverWait: Là chờ đợi động (Dynamic/Explicit Wait). Hàm này sẽ quét DOM liên tục mỗi 500ms. Ngay khi phần tử xuất hiện, nó sẽ thực thi ngay lập tức. Điều này giúp tối ưu hóa thời gian chạy và tăng độ ổn định của Bot lên đáng kể khi mạng chập chờn.

3) *Logic trích xuất và Xử lý ngoại lệ*: Hàm extract_full_details chịu trách nhiệm chuyển đổi các thẻ HTML thành dữ liệu có cấu trúc. Điểm đặc biệt ở đây là việc sử dụng try-except lồng nhau.

```
1 def extract_full_details(card_section, creator_id):
2     data = { ... } # Khoi tao Dictionary rong
3
4     try:
5         # 1. Trich xuất Giá (Price)
6         try:
7             # XPath phức tạp để tìm giá trị nam sau chu "Khoi diem tu"
```

```

8     price_xpath = "../span[contains(text(), 'Khoi diem tu')]/ancestor::div//div[contains(@class, '
↪ text-base')]"
9     price_elm = card_section.find_element(By.XPATH, price_xpath)
10    data["Start Price"] = price_elm.text.strip()
11    except:
12        # Neu khong tim thay gia, gan gia tri mac dinh thay vi de chuong trinh crash
13        data["Start Price"] = "Thoa thuan"
14
15    # 2. Tai anh Avatar
16    try:
17        avatar_img = card_section.find_element(By.XPATH, "../img")
18        url = avatar_img.get_attribute("src")
19        # Goi ham tai anh riêng biet
20        data["avatar_local_path"] = download_avatar(url, creator_id)
21    except: pass
22
23    except Exception: pass
24    return data

```

Listing 3. Trích xuất dữ liệu với cơ chế chịu lỗi

Phân tích: Cấu trúc HTML của TikTokOne không đồng nhất cho mọi Creator. Có người có giá, có người ẩn giá. Có người có 3 tags, có người không có tag nào.

- Việc bọc từng khối trích xuất (Price, Avatar, Metrics) trong các khối try-except riêng biệt đảm bảo rằng: **Nếu một trường dữ liệu bị lỗi, Bot vẫn tiếp tục lấy các trường còn lại**, không bỏ qua toàn bộ Creator đó. Đây là nguyên tắc "Fail-safe" trong thiết kế Crawler.

4) *Cơ chế Anti-Ban và Cuộn trang:* Để thu thập được 10,000 mẫu mà không bị chặn, chúng tôi áp dụng chiến thuật "Mô phỏng hành vi con người" (Human Emulation).

```

1    while new_items_count < TARGET_NEW_ITEMS:
2        # 1. Nghỉ giải lao (Break Time)
3        if new_items_count > 0 and new_items_count % 100 == 0:
4            print(f"\n>>> [ANTI-BAN] Sleeping 60s...")
5            time.sleep(60)
6            # Cuon nguoc len nhe de gia lap nguoi dung dang doc lai
7            driver.execute_script("window.scrollTo(0, -200);")
8
9        # 2. Logic cuộn trang thông minh
10       if max_row_idx == last_highest_index:
11           retry_scroll += 1
12           # Neu bi ket, thu cuon len roi cuon manh xuong
13           if retry_scroll >= 5:
14               driver.execute_script("window.scrollTo(0, -300);")
15               time.sleep(1)
16               driver.execute_script("window.scrollTo(0, 1000);")

```

Listing 4. Logic chống chặn và nghỉ giải lao

Giải thích:

- Hệ thống tự động nghỉ 60 giây sau mỗi 100 profiles. Điều này làm giảm tần suất request gửi đến server, tránh bị WAF (Web Application Firewall) của TikTok đánh dấu là tấn công DDoS.
- Logic cuộn trang không chỉ đơn thuần là cuộn xuống đáy. Nếu phát hiện không có dữ liệu mới (bị kẹt), Bot sẽ thực hiện động tác "nhích lên - cuộn xuống" để kích thích sự kiện Lazy Load của trình duyệt.

VI. TRUY VẤN VÀ KHÁM PHÁ DỮ LIỆU TRÊN MONGODB

Để kiểm tra tính toàn vẹn và hiểu rõ hơn về cấu trúc dữ liệu đã thu thập, chúng tôi thực hiện các câu truy vấn trực tiếp trên cơ sở dữ liệu MongoDB (Collection: `creators_vn1`). Dưới đây là các mẫu truy vấn điển hình:

A. Truy vấn mẫu dữ liệu đầu tiên

Để kiểm tra cấu trúc của các bản ghi (Document) và đảm bảo dữ liệu đã được nạp thành công, câu lệnh dưới đây lấy ra 20 nhà sáng tạo nội dung đầu tiên trong danh sách.

```
db.creators_vn1.find().limit(20)
```

```
< {
  _id: 'caonho',
  'Broadcast Score': '98.6',
  'Collab Score': '79.2',
  Country: 'Việt Nam',
  Engagement: '14,06%',
  Followers: '4,5M',
  ID: 'caonho',
  'Median Views': '372,6K',
  Name: 'CÁO NHỎ',
  'Start Price': 'Thỏa thuận/Chưa đặt',
  Tags: 'Thương mại điện tử (không dùng ứng dụng), Hài kịch, Thực phẩm và Đồ uống',
  avatar_local_path: 'D:\\Khanh\\hoc\\ma nguon mo\\New folder\\caonho.jpg',
  avatar_url: 'https://p16-sign-sg.tiktokcdn.com/tos-alisg-avt-0068/f445b76aed5525
}
{
  _id: 'maitrithuc2020',
  'Broadcast Score': '95.8',
  'Collab Score': '82.2',
  Country: 'Việt Nam',
  Engagement: '9,15%',
  Followers: '1,7M',
  ID: 'maitrithuc2020',
  'Median Views': '691,9K',
  Name: 'Mai Trí Thức',
  'Start Price': 'Thỏa thuận/Chưa đặt',
  Tags: 'Âm nhạc, Nhảy, Hát nhép',
  avatar_local_path: 'D:\\Khanh\\hoc\\ma nguon mo\\New folder\\maitrithuc2020.jpg',
  avatar_url: 'https://p16-sign-sg.tiktokcdn.com/tos-alisg-avt-0068/158854cdf83ddf
}
```

Hình 4. Kết quả truy vấn 20 bản ghi đầu tiên

B. Sắp xếp theo Tỷ lệ tương tác (Engagement)

Nhằm xác định những nhà sáng tạo có tầm ảnh hưởng lớn nhất, chúng tôi thực hiện sắp xếp giảm dần (-1) theo trường Engagement và lấy ra 20 kết quả hàng đầu.

```
db.creators_vn1.find().sort({ "Engagement": -1 }).limit(20)
```

```
> db.creators_vn1.find().sort({ "Engagement": -1 }).limit(20)
< [
  {
    '_id': 'hanhan838699',
    'Broadcast Score': 'N/A',
    'Collab Score': 'N/A',
    'Country': 'Unknown',
    'Engagement': 'N/A',
    'Followers': 'N/A',
    'ID': 'hanhan838699',
    'Median Views': 'N/A',
    'Name': 'N/A',
    'Start Price': 'Thỏa thuận/Chưa đặt',
    'Tags': '',
    'avatar_local_path': '',
    'avatar_url': ''
  },
  {
    '_id': 'sai_gon_tien_chuyen',
    'Broadcast Score': 'N/A',
    'Collab Score': 'N/A',
    'Country': 'Việt Nam',
    'Engagement': 'N/A',
    'Followers': 'N/A',
    'ID': 'sai_gon_tien_chuyen',
    'Median Views': 'N/A',
    'Name': '💎 TAXI GIÁ RẺ 💎 SÀI GÒN 🟩',
    'Start Price': 'Thỏa thuận/Chưa đặt',
    'Tags': ''
  }
]
```

Hình 5. Top 20 nhà sáng tạo có tỷ lệ tương tác cao nhất

C. Thống kê dữ liệu ẩn giá

Như đã phân tích ở phần trước, nhiều nhà sáng tạo không công khai giá booking. Câu lệnh sau đếm số lượng tài liệu không có trường Start Price hoặc có giá trị là "Thỏa thuận/Chưa đặt".

```
db.creators_vn1.countDocuments({
  $or: [
    { "Start Price": { $exists: false } },
    { "Start Price": "Thỏa thuận/Chưa đặt" }
  ]
})
```

```
> db.creators_vn1.countDocuments({
  $or: [ { "Start Price": { $exists: false } }, { "Start Price": "Thỏa thuận/Chưa đặt" } ]
})
< 5864
```

Hình 6. Kết quả đếm số lượng nhà sáng tạo không công khai giá

D. Tìm kiếm theo từ khóa (Regex)

Để lọc ra các tài khoản chính thức (thường có chữ "Official" trong tên), chúng tôi sử dụng biểu thức chính quy (Regex) với tùy chọn `i` (không phân biệt hoa thường).

```
db.creators_vn1.find({
  "Name": { $regex: /official/i }
});
```

```
> db.creators_vn1.find({
  "Name": { $regex: /official/i }
})
< {
  _id: 'khanhvyccf',
  'Broadcast Score': '91.6',
  'Collab Score': '77.7',
  Country: 'Việt Nam',
  Engagement: '6,75%',
  Followers: '2,6M',
  ID: 'khanhvyccf',
  'Median Views': '397,8K',
  Name: 'Khánh Vy Official',
  'Start Price': 'Thỏa thuận/Chưa đặt',
  Tags: 'Công nghệ & Đồ điện tử, Phim ảnh & Truyền hình, Thiết bị, Phát triển nghề nghiệp, Cuộc sống hàng ngày',
  avatar_local_path: 'D:\\Khanh\\hoc\\ma nguon mo\\New folder\\IMAGE_FOLDER\\khanhvyccf.jpg',
  avatar_url: 'https://p16-sign-sg.tiktokcdn.com/tos-alisg-avt-0068/42e2ed6d79038f63f25006a8bccf73f6-tplv-photomode-zoomcover-tcm:200:200.jpeg?dr
}
{
  _id: 'tunpham97',
  'Broadcast Score': 'N/A',
  'Collab Score': '86.6',
  Country: 'Việt Nam',
  Engagement: '0,52%',
  Followers: '4,5M',
  ID: 'tunpham97',
  'Median Views': '90K',
  Name: 'Tun Phạm Official',
```


Hình 7. Tìm kiếm các tài khoản có tên chứa từ khóa "Official"

VII. KẾT QUẢ VÀ PHÂN TÍCH DỮ LIỆU

Trong chương này, chúng tôi trình bày các kết quả thu được từ quá trình phân tích dữ liệu khám phá (Exploratory Data Analysis - EDA) trên tập dữ liệu đã thu thập. Mục tiêu chính là làm rõ các đặc điểm phân bố, phát hiện các mẫu hình tiềm ẩn (hidden patterns) và kiểm định các giả thuyết về hành vi của thị trường Influencer trên nền tảng TikTok. Quá trình phân tích được thực hiện dựa trên các phương pháp thống kê mô tả và trực quan hóa dữ liệu hiện đại [6].

A. Phân tích cấu trúc và Dữ liệu khuyết (Missing Values)

Bước đầu tiên và quan trọng nhất trong quy trình phân tích dữ liệu là đánh giá chất lượng và mức độ toàn vẹn của tập dữ liệu. Biểu đồ nhiệt (heatmap) về tỷ lệ giá trị khuyết dưới đây cung cấp cái nhìn tổng quan về mức độ sẵn có của thông tin trên từng trường dữ liệu.



Hình 8. Tỷ lệ phần trăm giá trị khuyết trên từng thuộc tính

Kết quả trực quan hóa cho thấy sự phân hóa rõ rệt về độ tin cậy giữa các biến:


- **Nhóm biến định danh và tương tác:** Các thuộc tính cốt lõi như *ID*, *Name*, *Followers*, *Engagement* đạt mức độ hoàn thiện dữ liệu rất cao (gần 100%). Điều này chứng tỏ hiệu quả của quy trình thu thập dữ liệu tự động (Crawler) trong việc trích xuất các thông tin công khai trên giao diện người dùng.
- **Biến Giá cả (Price):** Một hiện tượng dị biệt được ghi nhận ở cột *Price* với tỷ lệ thiếu hụt lên tới hơn 60%. Trong ngữ cảnh khoa học dữ liệu thông thường, tỷ lệ này có thể dẫn đến quyết định loại bỏ biến số. Tuy nhiên, đặt trong bối cảnh đặc thù của thương mại xã hội (Social Commerce), đây không phải là lỗi ngẫu nhiên (Missing Completely At Random - MCAR) mà là dạng "**Khuyết có thông tin**" (Informative Missingness) [7].

Sự thiếu hụt dữ liệu giá phản ánh một chiến lược kinh doanh phổ biến trên thị trường Influencer Marketing: chiến lược *****Phân biệt giá cấp một***** hoặc văn hóa *****Inbox giá***** [2]. Các Influencer, đặc biệt là nhóm vừa và nhỏ, thường cố tình ẩn giá công khai để duy trì lợi thế đàm phán, cho phép họ đưa ra các mức giá linh hoạt tùy thuộc vào quy mô và ngân sách của từng nhãn hàng. Do đó, thay vì

sử dụng các kỹ thuật điền khuyết (Imputation) thông thường như điền trung bình (Mean) hay trung vị (Median) có thể gây sai lệch bản chất phân phối, phương pháp tiếp cận tối ưu là chuyển đổi biến này thành biến phân loại nhị phân (Binary Variable: *Has_Price* vs *No_Price*) để đưa vào các mô hình phân tích hành vi sau này.

B. Đặc điểm phân phối của các chỉ số hiệu suất chính (KPIs)

Để hiểu rõ hơn về bức tranh tổng thể của hệ sinh thái Influencer, chúng tôi sử dụng biểu đồ kết hợp giữa Histogram và Đa giác tần số (Kernel Density Estimate - KDE) để phân tích ba chỉ số hiệu suất quan trọng nhất: Quy mô khán giả (Followers), Chất lượng nội dung (Engagement Rate) và Uy tín thương hiệu (Collab Score) [6].



Hình 9. Phân phối xác suất của Followers, Engagement Rate và Collab Score

Biểu đồ trên cung cấp những nhận định sâu sắc về cấu trúc thị trường:

1) *Phân phối Lượng người theo dõi (Followers)*: Dữ liệu Followers tuân theo quy luật phân phối *****Cái đuôi dài***** (Long-tail Distribution) điển hình của các mạng xã hội. Do khoảng biến thiên quá lớn (từ vài nghìn đến hàng chục triệu), chúng tôi đã áp dụng biến đổi Logarit cơ số 10 ($\log_{10}$) để chuẩn hóa dữ liệu về dạng phân phối chuẩn (Normal Distribution). Kết quả cho thấy đỉnh của phân phối tập trung ở ngưỡng 10⁵ (100.000 followers). Điều này khẳng định rằng thị trường hiện tại đang được chi phối bởi lực lượng *Micro-Influencers*. Đây là nhóm đối tượng được các nhãn hàng ưa chuộng nhất hiện nay do chi phí hợp lý và khả năng tiếp cận tệp khách hàng ngách (Niche Market) hiệu quả hơn so với các *Mega-Influencers* [1].

2) *Phân phối Tỷ lệ tương tác (Engagement Rate)*: Biểu đồ Engagement Rate thể hiện sự phân phối lệch phải (Right-skewed) rất mạnh.


- **Vùng tập trung**: Đại đa số các tài khoản (mode) chỉ đạt mức tương tác khiêm tốn từ 0% đến 5%. Đây là mức trung bình ngành phổ biến khi nền tảng TikTok ngày càng bão hòa về nội dung.
- **Vùng đuôi phải (Outliers)**: Phần đuôi kéo dài về phía giá trị dương đại diện cho các trường hợp ngoại lệ (Viral contents) đạt tỷ lệ tương tác trên 20%. Những điểm dữ liệu này thường thuộc về các tài khoản mới nổi hoặc các nội dung "bắt trend" cực nhanh.
- **Nghịch lý quy mô**: Dữ liệu cũng củng cố giả thuyết về sự đánh đổi giữa Quy mô và Tương tác: khi lượng Follower tăng lên, rất khó để duy trì tỷ lệ Engagement cao do sự loãng của tệp fan (Audience Dilution Effect) [2].

3) *Phân phối Điểm hợp tác (Collab Score)*: Chỉ số Collab Score thể hiện tính chất phân phối đa đỉnh (Multimodal Distribution), phản ánh sự phân tầng rõ rệt về chất lượng Influencer:

- **Đỉnh chính (75-80 điểm)**: Nhóm Influencer hoạt động tích cực, có lịch sử hợp tác tốt.
- **Đỉnh phụ (60-62 điểm)**: Nhóm Influencer mới gia nhập thị trường hoặc thiếu dữ liệu lịch sử, được hệ thống gán mức điểm sàn mặc định.

C. Phân tích hành vi tương tác theo Chủ đề nội dung (Content Analysis)

Mối quan hệ giữa loại hình nội dung và hiệu quả tương tác là chìa khóa để xây dựng chiến lược nội dung (Content Strategy). Biểu đồ hộp (Boxplot) dưới đây so sánh phân phối tỷ lệ tương tác của 10 nhóm chủ đề (Tags) phổ biến nhất trong tập dữ liệu.



Hình 10. So sánh mức độ phân tán Tỷ lệ tương tác theo Top 10 Chủ đề


Phân tích biểu đồ cho thấy sự phân cực rõ rệt về hiệu quả giữa hai nhóm nội dung chiến lược:

- Nhóm nội dung "Giải trí nhanh"(Instant Gratification):** Bao gồm các thể như *Selfie (Ảnh tự chụp)*, *Lip-sync (Hát nhép)*, *Dancing (Nhảy)*. Nhóm này thể hiện mức trung vị (Median) cao vượt trội ($\approx 8\%$) và độ biến thiên (Interquartile Range) rất rộng. Điều này phản ánh tâm lý hành vi của người dùng TikTok: ưu tiên sự kết nối cảm xúc tức thời, tính giải trí nhẹ nhàng và hình ảnh cá nhân chân thực. Đây là các loại nội dung dễ dàng đạt được hiệu ứng lan truyền (Viral) nhất [8].
- Nhóm nội dung "Chuyên sâu"(Information-based):** Bao gồm *Tutorials (Hướng dẫn)*, *News (Tin tức)*, *Gaming*. Mặc dù mang lại giá trị thông tin cao, nhóm này lại có mức tương tác trung bình thấp hơn đáng kể (3-4%) và phân bố dữ liệu khá hẹp (ít đột biến). Nguyên nhân có thể do nội dung chuyên sâu đòi hỏi sự tập trung cao độ từ người xem, dẫn đến rào cản tương tác cao hơn so với nội dung giải trí thuần túy.

****Hàm ý quản trị:**** Các nhãn hàng khi booking KOLs thuộc nhóm chuyên môn (như Gaming/Tech) không nên kỳ vọng quá cao vào các chỉ số tương tác bề nổi (Like/Share) mà nên tập trung vào độ sâu của tệp khách hàng (Conversion Rate). Ngược lại, để tối ưu hóa nhận diện thương hiệu (Brand Awareness), nhóm giải trí là lựa chọn tối ưu.

D. Kiểm định đa cộng tuyến và Mối quan hệ giữa các biến

Để kiểm tra cấu trúc phụ thuộc giữa các biến số lượng, chúng tôi xây dựng Ma trận tương quan Pearson (Pearson Correlation Matrix). Bước này giúp phát hiện các mối quan hệ tiềm ẩn và hiện tượng đa cộng tuyến (Multicollinearity) có thể ảnh hưởng đến các mô hình học máy [6].



Hình 11. Ma trận hệ số tương quan nhiệt (Correlation Heatmap)


Kết quả phân tích định lượng chỉ ra những phát hiện đáng chú ý:

- **Sự độc lập tuyến tính mạnh mẽ:** Hầu hết các cặp biến số đều có hệ số tương quan r xấp xỉ 0 (màu tím đậm trên bản đồ nhiệt). Điều này cho thấy các chỉ số hoạt động trên TikTok có tính độc lập rất cao. Ví dụ, việc sở hữu lượng *Followers* khổng lồ không đảm bảo tuyến tính cho việc có nhiều *Median_Views* ($r = 0.21$) hay *Engagement* cao ($r \approx 0$).
- **Thách thức trong định giá:** Biến mục tiêu *Price* gần như không có tương quan tuyến tính với bất kỳ biến đầu vào nào. Điều này bác bỏ giả định đơn giản rằng "Càng nhiều Follower thì giá càng cao". Thực tế này gợi ý rằng cơ chế định giá Influencer là một hàm phi tuyến tính phức tạp, phụ thuộc vào nhiều yếu tố định tính (như hình ảnh thương hiệu, độ phù hợp ngành hàng) hơn là các con số định lượng bề nổi.

Kết luận này định hướng cho việc lựa chọn mô hình dự báo: các mô hình hồi quy tuyến tính đơn giản (Linear Regression) sẽ không hiệu quả. Cần áp dụng các thuật toán phi tuyến tính mạnh mẽ hơn như **Random Forest** hoặc **XGBoost** để nắm bắt được các mẫu hình phức tạp này trong dữ liệu [7].

E. Kiểm định giả thuyết: Sự minh bạch giá và Quy mô tài khoản

Cuối cùng, chúng tôi thực hiện kiểm định giả thuyết về mối quan hệ giữa hành vi công khai giá và vị thế của Influencer trên thị trường. Biểu đồ hộp so sánh phân phối lượng Followers giữa hai nhóm *Has_Price* (Có giá) và *No_Price* (Ẩn giá).



Hình 12. Phân tích so sánh lượng Follower theo trạng thái công khai giá

Biểu đồ cho thấy sự tách biệt rõ ràng giữa hai nhóm:

- **Nhóm Công khai giá (Màu xanh):** Có trung vị (median) cao hơn và khoảng tứ phân vị (IQR box) nằm ở vùng giá trị lớn hơn trên trục tung. Điều này chỉ ra rằng các tài khoản có quy mô lớn (Macro/Mega Influencers) có xu hướng minh bạch hóa chi phí booking. Đây có thể là dấu hiệu của sự chuyên nghiệp hóa (Professionalism) trong quy trình vận hành, giúp họ tiết kiệm thời gian đàm phán và lọc được các đối tác phù hợp ngay từ đầu.
- **Nhóm Ẩn giá (Màu cam):** Tập trung chủ yếu ở phân khúc Micro/Nano Influencers. Việc ẩn giá giúp nhóm này duy trì sự linh hoạt trong đàm phán và tối đa hóa cơ hội tiếp cận với nhiều loại hình nhãn hàng khác nhau.

Phát hiện này cung cấp một biến đặc trưng (Feature) quan trọng cho bài toán phân loại Influencer: Hành vi công khai giá có thể được sử dụng như một chỉ báo (proxy) cho mức độ chuyên nghiệp và quy mô của tài khoản [1].

VIII. KIỂM THỬ VÀ ĐÁNH GIÁ HỆ THỐNG

Để đảm bảo hệ thống hoạt động chính xác và ổn định trước khi đưa vào sử dụng thực tế, quy trình kiểm thử phần mềm (Software Testing) đã được thực hiện nghiêm ngặt. Chúng tôi áp dụng phương pháp Kiểm thử hộp đen (Black-box Testing) tập trung vào các chức năng nghiệp vụ và Kiểm thử hiệu năng (Performance Testing).

A. Xây dựng Kịch bản kiểm thử (Test Cases)

Dưới đây là bảng mô tả chi tiết các kịch bản kiểm thử chức năng (Functional Testing).

1) *Kiểm thử chức năng Khởi tạo và Đăng nhập*: Mục tiêu: Đảm bảo Bot có thể khởi động trình duyệt và duy trì phiên đăng nhập thông qua Profile.

Bảng VI
TEST CASE: KHỞI TẠO HỆ THỐNG

Mã TC	Mô tả kịch bản	Kết quả mong đợi	Trạng thái
TC_01	Chạy Bot khi không có kết nối Internet.	Hệ thống báo lỗi "Connection Error" và tự động thử lại sau 5s.	Đạt
TC_02	Chạy Bot với đường dẫn Profile sai.	Hệ thống báo lỗi "Profile not found" và dừng chương trình.	Đạt
TC_03	Chạy Bot với cấu hình đúng.	Firefox mở lên, tự động vào trang TikTokOne mà không cần đăng nhập lại.	Đạt

2) *Kiểm thử chức năng Thu thập dữ liệu*: Mục tiêu: Đảm bảo dữ liệu được trích xuất chính xác từ giao diện HTML.

Bảng VII
TEST CASE: THU THẬP DỮ LIỆU

Mã TC	Mô tả kịch bản	Kết quả mong đợi	Trạng thái
TC_04	Creator có đầy đủ thông tin (Follower, Price, Email).	Dữ liệu lưu vào MongoDB đầy đủ các trường.	Đạt
TC_05	Creator ẩn giá (Price).	Trường Price trong DB ghi nhận giá trị "Thỏa thuận" hoặc null.	Đạt
TC_06	Creator có tên chứa ký tự đặc biệt (Emoji, tiếng Thái...).	Dữ liệu lưu vào DB không bị lỗi font (UTF-8).	Đạt
TC_07	Mạng bị lag, ảnh Avatar tải chậm.	Bot chờ (Explicit Wait) đến khi ảnh tải xong hoặc timeout sau 10s rồi bỏ qua.	Đạt

3) *Kiểm thử chức năng Chống chặn (Anti-Ban)*: Mục tiêu: Đảm bảo Bot không bị TikTok chặn khi chạy số lượng lớn.

Bảng VIII
TEST CASE: CƠ CHẾ ANTI-BAN

Mã TC	Mô tả kịch bản	Kết quả mong đợi	Trạng thái
TC_08	Chạy liên tục 100 profiles.	Sau profile thứ 100, Bot dừng lại, in log "Sleeping..." và nghỉ 60 giây.	Đạt
TC_09	Cuộn trang xuống đáy nhưng không có dữ liệu mới (Lazy load chưa kịp).	Bot thực hiện cuộn lên/xuống nhẹ để kích thích loading. Không bị crash.	Đạt

B. Đánh giá Hiệu năng (Performance Evaluation)

Chúng tôi đã tiến hành đo đạc thời gian thực thi của hệ thống trên tập mẫu 1,000 bản ghi để đánh giá tốc độ trung bình.

Bảng IX
KẾT QUẢ ĐO LƯỜNG HIỆU NĂNG

Chỉ số	Giá trị trung bình	Đánh giá
Thời gian khởi động Browser	4.5 giây	Chấp nhận được
Thời gian xử lý 1 Creator	1.2 giây	Nhanh
Tốc độ tải ảnh Avatar	0.8 giây/ảnh	Phụ thuộc mạng
Tổng thời gian cho 1000 items	$\approx$ 45 phút	Ổn định

Kết quả cho thấy thời gian xử lý tăng tuyến tính theo số lượng bản ghi, chứng tỏ thuật toán không có độ phức tạp lũy thừa, phù hợp để mở rộng lên quy mô 10,000 mẫu.

IX. THẢO LUẬN

Dựa trên các kết quả phân tích định lượng và trực quan hóa dữ liệu ở các phần trước, chương này sẽ đi sâu vào việc giải thích ý nghĩa của các con số, đặt chúng trong bối cảnh rộng lớn hơn của nền kinh tế thương mại xã hội (Social Commerce). Chúng tôi tập trung thảo luận ba khía cạnh cốt lõi phản ánh thực trạng dữ liệu và hành vi thị trường.

A. Sự "mờ đục" của thị trường và chiến lược định giá (Price Opacity)

Một trong những phát hiện thống kê quan trọng nhất của dự án là tỷ lệ dữ liệu khuyết (Missing Value) lên tới hơn 60% tại cột *Price*. Trong các tập dữ liệu truyền thống, đây thường bị coi là dữ liệu rác hoặc lỗi kỹ thuật. Tuy nhiên, dưới góc độ khoa học dữ liệu kết hợp với kiến thức miền (Domain Knowledge), sự thiếu hụt này mang tính chất "Khuyết có thông tin" (Informative Missingness).

Hiện tượng này phản ánh tình trạng **"Bất cân xứng thông tin"** (Information Asymmetry) trên thị trường Influencer Marketing. Các nhà sáng tạo nội dung, đặc biệt là nhóm vừa và nhỏ, có xu hướng áp dụng chiến lược "Inbox để biết giá" nhằm mục đích:

- **Phân biệt giá (Price Discrimination):** Cho phép họ đưa ra các mức giá khác nhau cho từng nhãn hàng dựa trên ngân sách và khả năng chi trả của đối tác, thay vì bị ràng buộc bởi một mức giá niêm yết công khai [1].
- **Tăng cường tương tác:** Việc buộc khách hàng phải liên hệ trực tiếp tạo ra cơ hội đàm phán và thiết lập mối quan hệ cá nhân, thay vì bị loại ngay từ vòng tham khảo giá.

Khi đối chiếu với biểu đồ hộp về phân bố lượng người theo dõi, ta thấy nhóm "Công khai giá" có trung vị Follower cao hơn đáng kể. Điều này chỉ ra một sự chuyển dịch trong mô hình hoạt động: Khi quy mô của Influencer đạt đến ngưỡng Macro hoặc Mega (hàng triệu người theo dõi), chi phí giao dịch (transaction cost) cho việc đàm phán thủ công trở nên quá lớn. Lúc này, sự minh bạch về giá cả (Rate Card công khai) trở thành dấu hiệu của sự chuyên nghiệp hóa (Professionalism) và quy chuẩn hóa quy trình vận hành [2].

B. Nghịch lý về Nội dung: Giải trí thắng thế Chuyên môn

Kết quả phân tích từ biểu đồ hộp về *Tags* đã phơi bày một thực tế thú vị nhưng cũng đầy thách thức: các nội dung đòi hỏi ít chất xám kịch bản nhưng mang tính giải trí và cá nhân hóa cao (như *Selfie*, *Lip-sync*, *Dancing*) lại đạt tỷ lệ tương tác (Engagement Rate) trung bình khoảng 8%, vượt trội hoàn toàn so với các nội dung chuyên sâu (như *Tutorials*, *News*, *Gaming* chỉ đạt 3-4%).

Nghịch lý này có thể được giải thích qua cơ chế tâm lý **"Thỏa mãn tức thời"** (Instant Gratification) và hành vi tiêu thụ nội dung dạng ngắn (Short-form content consumption). Người dùng TikTok có xu hướng tìm kiếm các kết nối cảm xúc nhanh (dopamine hit) thông qua các video giải trí nhẹ nhàng hơn là việc phải bỏ ra nỗ lực nhận thức (cognitive effort) để tiếp thu kiến thức từ các video hướng dẫn [2].

Tuy nhiên, đối với các nhãn hàng, điều này đặt ra một bài toán đánh đổi chiến lược giữa **Độ phủ (Reach)** và **Sự tin cậy (Trust)**:

- Nhóm *Entertainer* (Giải trí) phù hợp cho mục tiêu tăng nhận diện thương hiệu (Brand Awareness) ở đầu phễu marketing nhờ khả năng Viral cao.
- Nhóm *Expert* (Chuyên gia) tuy có tương tác thấp hơn nhưng lại sở hữu tệp khán giả có ý định (intent) rõ ràng hơn, phù hợp cho mục tiêu chuyển đổi (Conversion) ở cuối phễu [8].

C. Thách thức phi tuyến tính trong việc dự báo giá trị

Ma trận tương quan Pearson cho thấy các chỉ số định lượng như *Followers*, *Median Views*, *Engagement* và *Price* có hệ số tương quan rất thấp (xấp xỉ 0). Phát hiện này phá vỡ giả định tuyến tính thông thường rằng "Càng nhiều Follower thì giá càng cao" hay "Càng nhiều Follower thì tương tác càng lớn" [6].

Điều này hàm ý rằng thị trường Influencer là một hệ thống phức tạp và phi tuyến tính (Non-linear system). Giá trị của một Influencer không chỉ được định đoạt bởi các "chỉ số phù phiếm" (Vanity Metrics)

như số lượng người theo dõi, mà còn phụ thuộc vào các biến số định tính ẩn (Latent Variables) mà quá trình cào dữ liệu chưa nắm bắt được, ví dụ như:

- **Độ trung thành của tệp fan (Fan Loyalty):** Một Micro-influencer với 50k follower nhưng có cộng đồng cuồng nhiệt (Niche market) có thể có giá trị thương mại cao hơn một tài khoản 1 triệu follower nhưng tệp fan lỏng.
- **Chất lượng thẩm mỹ và sự an toàn thương hiệu (Brand Safety):** Hình ảnh chuyên nghiệp và nội dung sạch sẽ là yếu tố then chốt quyết định giá booking [1].

Từ góc độ Khoa học dữ liệu, kết luận này bác bỏ khả năng sử dụng các mô hình Hồi quy tuyến tính đơn biến (Linear Regression). Để xây dựng mô hình định giá tự động (Automated Valuation Model) chính xác, hướng nghiên cứu tiếp theo cần áp dụng các thuật toán học máy phi tuyến tính (như Random Forest, Gradient Boosting) hoặc tích hợp thêm xử lý ngôn ngữ tự nhiên (NLP) để phân tích nội dung Bio và Caption [7].

X. KẾT LUẬN VÀ KIẾN NGHỊ

A. Kết luận chung

Nghiên cứu này đã thực hiện thành công quy trình thu thập và phân tích dữ liệu quy mô lớn về các nhà sáng tạo nội dung trên TikTokOne, cung cấp một bức tranh toàn cảnh và khách quan về hệ sinh thái Influencer tại Việt Nam. Những phát hiện chính bao gồm:

- **Thực trạng dữ liệu và văn hóa thị trường:** Mặc dù thông tin định danh và chỉ số hoạt động (Views, Followers) có độ tin cậy cao, sự thiếu hụt nghiêm trọng (hơn 60%) dữ liệu về giá cả (*Price*) không phải là lỗi hệ thống mà là đặc điểm cố hữu của thị trường. Nó phản ánh sự thiếu chuẩn hóa trong định giá và văn hóa "thỏa thuận ngầm" vẫn đang bao trùm, đặc biệt ở phân khúc Influencer vừa và nhỏ [1].
- **Cấu trúc phân tầng của hệ sinh thái:** Thị trường bị chi phối bởi quy luật "Cái đuôi dài" (Long Tail), với sự áp đảo về số lượng của các *Micro-Influencers* ($\sim 10^5$ followers). Mặc dù tỷ lệ tương tác trung bình của nhóm này đã giảm xuống mức thấp ($< 5\%$) do sự bão hòa nội dung, nhưng chỉ số *Collab Score* vẫn ở mức khả quan, cho thấy mức độ chuyên nghiệp trong việc hợp tác với nhãn hàng đang dần được cải thiện.
- **Xu hướng nội dung và sự đánh đổi:** Dữ liệu khẳng định sự thắng thế của nội dung mang tính cá nhân hóa cao (*Selfie*) và giải trí nhanh (*Entertainment*). Có một sự đánh đổi rõ rệt giữa "Độ sâu chuyên môn" và "Độ rộng lan tỏa". Ngoài ra, mối tương quan dương giữa việc công khai giá và quy mô tài khoản cho thấy sự minh bạch là bước chuyển mình cần thiết để một Creator tiến lên phân khúc chuyên nghiệp (Professional Creator Economy).

B. Kiến nghị và Hướng phát triển

Dựa trên những hạn chế hiện tại và các "insight" rút ra từ dữ liệu, chúng tôi đề xuất các hướng tiếp cận chiến lược cho giai đoạn tiếp theo, chia làm hai khía cạnh: Kỹ thuật và Ứng dụng.

1) Về mặt Kỹ thuật và Khoa học dữ liệu:

- 1) **Chiến lược xử lý dữ liệu khuyết nâng cao:** Thay vì loại bỏ hoặc điền trung bình một cách ngây thơ, cần áp dụng các kỹ thuật *Imputation* dựa trên mô hình học máy. Cụ thể, đề xuất sử dụng thuật toán **KNN (K-Nearest Neighbors)** để dự đoán giá trị *Price* bị thiếu dựa trên sự tương đồng của các láng giềng (về Tags, Followers, Views). Đồng thời, nên tạo thêm biến đặc trưng (Feature Engineering) như *is_price_hidden* để mô hình học được hành vi giấu giá [6].
- 2) **Mô hình hóa phi tuyến tính:** Do ma trận tương quan cho thấy các biến số độc lập tuyến tính, các mô hình hồi quy truyền thống (Linear Regression) sẽ không hiệu quả. Cần chuyển sang các thuật toán học máy phi tuyến tính mạnh mẽ hơn như **Random Forest** hoặc **XGBoost/LightGBM**. Các mô hình này có khả năng nắm bắt được các tương tác phức tạp và phi tuyến tính giữa các biến số để dự báo chính xác giá trị thương mại của Influencer [7].
- 3) **Tích hợp Xử lý ngôn ngữ tự nhiên (NLP):** Mở rộng phạm vi thu thập dữ liệu sang nội dung văn bản (Bio, Caption, Hashtags). Áp dụng các kỹ thuật NLP (như TF-IDF, Word2Vec hoặc BERT) để phân tích sắc thái tình cảm (Sentiment Analysis) và chủ đề nội dung sâu hơn, thay vì chỉ dựa vào các thẻ Tags có sẵn.

2) Về mặt Chiến lược Nội dung và Marketing:

- 1) **Mô hình "Edutainment" (Giáo dục kết hợp Giải trí):** Đối với các Influencer thiên về chuyên môn (Expertise), việc chỉ cung cấp kiến thức khô khan là chưa đủ để cạnh tranh. Kiến nghị áp dụng chiến lược "Edutainment" lồng ghép yếu tố giải trí, kể chuyện (Storytelling) hoặc chia sẻ đời sống cá nhân (Lifestyle) để phá vỡ rào cản tương tác, cải thiện chỉ số Engagement đang ở mức thấp [2].
- 2) **Tối ưu hóa danh mục đầu tư (Portfolio Optimization):** Các nhãn hàng không nên dồn toàn bộ ngân sách vào một nhóm đối tượng. Cần xây dựng danh mục hợp tác đa dạng: sử dụng nhóm *Entertainer* để tối đa hóa nhận diện thương hiệu (Brand Awareness) và nhóm *Expert/Micro-Influencer* để thúc

đẩy niềm tin và chuyển đổi đơn hàng (Conversion), tận dụng thế mạnh riêng biệt mà dữ liệu đã chỉ ra [8].

PHỤ LỤC A

MÃ NGUỒN CHƯƠNG TRÌNH (SOURCE CODE)

Hệ thống được triển khai dưới dạng một tập tin kịch bản (script) Python duy nhất. Dưới đây là mã nguồn chi tiết:

```
1 import time
2 import random
3 import re
4 import requests
5 import pandas as pd
6 import os
7 from selenium import webdriver
8 from selenium.webdriver.firefox.service import Service
9 from selenium.webdriver.common.by import By
10 from selenium.webdriver.support.ui import WebDriverWait
11 from selenium.webdriver.support import expected_conditions as EC
12 from selenium.common.exceptions import StaleElementReferenceException
13 from webdriver_manager.firefox import GeckoDriverManager
14 from selenium.webdriver.common.action_chains import ActionChains
15 from pymongo import MongoClient
16
17 # =====
18 # 1. CAU HINH (CONFIG)
19 # =====
20 # --- Cau hinh Selenium ---
21 # Lưu ý: Đường dẫn Profile và Firefox Binary cần được chỉnh sửa theo máy cá nhân
22 MY_PROFILE_PATH = r"C:\Users\User\AppData\Roaming\Mozilla\Firefox\Profiles\xxxx.default-release"
23 FIREFOX_BINARY_PATH = r"C:\Program Files\Mozilla Firefox\firefox.exe"
24 GECKO_PATH = r"D:\Drivers\geckodriver.exe"
25
26 IMAGE_FOLDER = r"D:\Data\IMAGE_FOLDER"
27 if not os.path.exists(IMAGE_FOLDER):
28     os.makedirs(IMAGE_FOLDER)
29
30 # --- Cau hinh MongoDB ---
31 MONGO_URI = "mongodb://localhost:27017/"
32 DB_NAME = "tiktok_ads_db"
33 COLLECTION_NAME = "creators_vn1"
34
35 TARGET_NEW_ITEMS = 10000
36
37 # =====
38 # 2. KET NOI MONGODB
39 # =====
40 try:
41     client = MongoClient(MONGO_URI)
42     db = client[DB_NAME]
43     collection = db[COLLECTION_NAME]
44     print(f"--- Connected MongoDB: {DB_NAME}.{COLLECTION_NAME} ---")
45
46     # Load ID đã có vào bộ nhớ
47     existing_ids = set(doc["_id"] for doc in collection.find({}, {"_id": 1}))
48     print(f"--- Loaded {len(existing_ids)} creators from DB ---")
49
50 except Exception as e:
51     print(f"Error MongoDB: {e}")
52     exit()
53
54 # =====
55 # 3. HELPER FUNCTIONS
56 # =====
57
58 def random_sleep(min_s=2, max_s=4):
59     time.sleep(random.uniform(min_s, max_s))
60
61 def safe_click(driver, xpath, retries=3):
62     """Click an toàn, tự động scroll"""
63     for i in range(retries):
64         try:
65             element = WebDriverWait(driver, 3).until(
66                 EC.presence_of_element_located((By.XPATH, xpath))
67             )
```

```

68         driver.execute_script("arguments[0].scrollIntoView({block: 'center'});", element)
69         time.sleep(1)
70         driver.execute_script("arguments[0].click();", element)
71         return True
72     except:
73         time.sleep(1)
74     return False
75
76 def get_creator_id_only(card_section):
77     """Chi lay ID de check trung"""
78     try:
79         id_elm = card_section.find_element(
80             By.XPATH,
81             ".*div[contains(@class, 'text-black') and contains(@class, 'font-semibold')]/div[contains(
↪ @class, 'truncated__text-single')]"
82         )
83         return id_elm.text.strip()
84     except:
85         return "N/A"
86
87 def download_avatar(url, creator_id):
88     """Tai anh tu URL -> Luu file -> Tra ve duong dan"""
89     if not url or url == "":
90         return ""
91
92     try:
93         safe_id = "".join([c for c in creator_id if c.isalnum() or c in ('-', '_', '.')])
94         filename = f"{safe_id}.jpg"
95         file_path = os.path.join(IMAGE_FOLDER, filename)
96
97         if os.path.exists(file_path) and os.path.getsize(file_path) > 0:
98             return file_path
99
100         headers = {
101             "User-Agent": "Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 ...",
102             "Referer": "https://www.tiktok.com/",
103         }
104
105         response = requests.get(url, headers=headers, timeout=10)
106         if response.status_code == 200:
107             with open(file_path, 'wb') as f:
108                 f.write(response.content)
109             return file_path
110         else:
111             return ""
112     except Exception as e:
113         return ""
114
115 def extract_full_details(card_section, creator_id):
116     """Logic trích xuất thông tin chi tiết"""
117     data = {
118         "_id": creator_id,
119         "ID": creator_id,
120         "Name": "N/A",
121         "Country": "N/A",
122         "Collab Score": "N/A",
123         "Followers": "N/A",
124         "Start Price": "N/A",
125     }
126
127     try:
128         # 1. Ten
129         try:
130             name_elm = card_section.find_element(
131                 By.XPATH,
132                 ".*div[contains(@class, 'text-neutral-onFillLow')]/div[contains(@class, 'truncated__text-
↪ single')]"
133             )
134             data["Name"] = name_elm.text.strip()
135         except: pass
136
137         # 2. Quoc gia
138         try:

```

```

139         country_elm = card_section.find_element(
140             By.XPATH,
141             "//*[@div[contains(@class, 'truncated__text-single') and text()='Việt Nam']]"
142         )
143         data["Country"] = country_elm.text.strip()
144     except: data["Country"] = "Unknown"
145
146     # 3. Metrics (Followers, Views...)
147     try:
148         metrics = card_section.find_elements(By.CSS_SELECTOR, ".text-base.font-semibold")
149         if len(metrics) >= 3:
150             data["Followers"] = metrics[0].text.strip()
151             data["Median Views"] = metrics[1].text.strip()
152             data["Engagement"] = metrics[2].text.strip()
153     except: pass
154
155     try:
156         # XPath tìm giá (Price) - Ngắt dòng để tránh tràn lề
157         price_xpath = (
158             "//*[@span[contains(text(), 'Khoi diem tu')]"
159             "/*ancestor::div//div[contains(@class, 'text-base')]"
160         )
161         price_elm = card_section.find_element(By.XPATH, price_xpath)
162         data["Start Price"] = price_elm.text.strip()
163     except:
164         data["Start Price"] = "Thỏa thuận" # Giá thỏa thuận
165
166     except Exception: pass
167     return data
168
169 # =====
170 # 4. MAIN PROGRAM
171 # =====
172
173 # Kill Firefox cũ nếu đang chạy
174 try:
175     os.system("taskkill /f /im firefox.exe")
176     time.sleep(2)
177 except: pass
178
179 print("--- START FIREFOX ---")
180 ser = Service(GECKO_PATH)
181 options = webdriver.firefox.options.Options()
182 options.binary_location = FIREFOX_BINARY_PATH
183 options.add_argument("-profile")
184 options.add_argument(MY_PROFILE_PATH)
185 options.set_preference("dom.webdriver.enabled", False)
186
187 driver = webdriver.Firefox(options=options, service=ser)
188 wait = WebDriverWait(driver, 20)
189
190 try:
191     driver.get("https://ads.tiktok.com/creative/creator/explore?region=row")
192     driver.maximize_window()
193     time.sleep(5)
194
195     print("\n--- AUTO FILTER ---")
196     # Tự động chọn bộ lọc Việt Nam
197     filter_trigger = "//*[@div[contains(@class, 'filter-trigger')]][1]"
198     if safe_click(driver, filter_trigger):
199         time.sleep(1)
200
201     # Chọn quốc gia Việt Nam
202     vn_option = "//*[@div[contains(@class, 'truncated') and text()='Việt Nam']]"
203     safe_click(driver, vn_option)
204
205     # Nhấn nút Áp dụng
206     apply_btn = "//*[@button[contains(text(), 'Áp dụng')]"
207     safe_click(driver, apply_btn)
208
209     time.sleep(5)
210
211     print("\n--- START CRAWLING ---")

```

```

212 new_items_count = 0
213
214 while new_items_count < TARGET_NEW_ITEMS:
215     # Co che Anti-ban: Nghi 60s sau moi 100 items
216     if new_items_count > 0 and new_items_count % 100 == 0:
217         print(f"\n>>> [ANTI-BAN] Sleeping 60s...")
218         time.sleep(60)
219         driver.execute_script("window.scrollTo(0, -200);")
220
221     visible_rows = driver.find_elements(By.CSS_SELECTOR, "div[data-index]")
222
223     for row in visible_rows:
224         try:
225             creator_cards = row.find_elements(By.TAG_NAME, "section")
226             for card in creator_cards:
227                 c_id = get_creator_id_only(card)
228
229                 # Chi lay ID chua ton tai trong DB
230                 if c_id not in existing_ids and c_id != "N/A":
231                     info = extract_full_details(card, c_id)
232
233                     # Luu vao MongoDB
234                     collection.update_one(
235                         {"_id": c_id},
236                         {"$set": info},
237                         upsert=True
238                     )
239                     existing_ids.add(c_id)
240                     new_items_count += 1
241                     print(f"[NEW] {info['ID']} | FL: {info['Followers']}")
242             except: continue
243
244     # Cuon trang (Scroll Logic)
245     driver.execute_script("window.scrollTo(0, 800);")
246     random_sleep(2, 3)
247
248 except Exception as e:
249     print(f"Error: {e}")
250 finally:
251     print("End.")

```

Listing 5. Mã nguồn đầy đủ (main.py)

PHỤ LỤC B MẪU DỮ LIỆU JSON

Dưới đây là một document mẫu được lưu trong MongoDB:

```

1 {
2   "_id": "user_demo_123",
3   "ID": "user_demo_123",
4   "Name": "Demo Creator",
5   "Country": "Việt Nam",
6   "Followers": "2.5M",
7   "Engagement": "5.8%",
8   "Broadcast Score": "88.4",
9   "Collab Score": "76.9",
10  "Median Views": "520.3K",
11  "Start Price": "5.000.000 VND",
12  "Tags": "Lifestyle, Fashion",
13  "avatar_local_path": "D:\\Data\\IMAGE_FOLDER\\user_demo_123.jpg",
14  "avatar_url": "https://example.cdn.com/avatar/user_demo_123.jpg"
15 }

```

```

1 {
2   "_id": "user_demo_456",
3   "avatar_base64": "/9j/4AAQSkZJRgABAQAAQABAAD/2wBDAAGBgcGBQgHBwcJCQgKDBQNDAsLDBkSEw8UHR...",
4   "avatar_url": "https://example.cdn.com/avatar/user_demo_456.jpg"
5 }

```

TÀI LIỆU THAM KHẢO

- [1] Influencer Marketing Hub, “The state of influencer marketing 2024: Benchmark report,” <https://influencermarketinghub.com/influencer-marketing-benchmark-report/>, 2024.
- [2] M. Haenlein and A. Kaplan, “A brief history of artificial intelligence: On the past, present, and future of artificial intelligence,” *California management review*, vol. 61, no. 4, pp. 5–14, 2019.
- [3] R. Mitchell, *Web Scraping with Python: Collecting More Data from the Modern Web*. "O'Reilly Media, Inc.", 2018.
- [4] “Selenium browser automation,” <https://www.selenium.dev/documentation/>, 2024, accessed: 2024-01-01.
- [5] “Mongodb documentation,” <https://www.mongodb.com/docs/>, 2024, accessed: 2024-01-01.
- [6] J. VanderPlas, *Python data science handbook: Essential tools for working with data*. "O'Reilly Media, Inc.", 2016.
- [7] A. Gandomi and M. Haider, “Beyond the hype: Big data concepts, methods, and analytics,” *International journal of information management*, vol. 35, no. 2, pp. 137–144, 2015.
- [8] C. Lou and S. Yuan, “Influencer marketing: How message value and credibility affect consumer trust of branded content on social media,” *Journal of Interactive Advertising*, vol. 19, no. 1, pp. 58–73, 2019.
- [9] “Python 3.12 documentation,” <https://docs.python.org/3/>, 2024.

PHỤ LỤC C

PHÂN CÔNG CÔNG VIỆC VÀ ĐÓNG GÓP THÀNH VIÊN

Để đảm bảo tiến độ và chất lượng của đồ án, nhóm nghiên cứu đã áp dụng mô hình làm việc cộng tác dựa trên nền tảng quản lý mã nguồn **GitHub**. Quy trình phát triển phần mềm tuân theo tiêu chuẩn *Git Feature Branch Workflow*, trong đó mỗi tính năng mới được phát triển trên một nhánh riêng biệt trước khi được kiểm thử và gộp (merge) vào nhánh chính.

Dựa trên lịch sử Commit (Commit History) và danh sách các yêu cầu kéo (Pull Requests) được ghi nhận lại trên Repository, vai trò và trách nhiệm cụ thể của từng thành viên được chi tiết hóa trong các mục dưới đây.

A. Tổng hợp phân công nhiệm vụ

Bảng X dưới đây tóm tắt các hạng mục công việc chính mà mỗi thành viên đảm nhận. Sự phân chia này dựa trên thế mạnh kỹ thuật của từng cá nhân nhằm tối ưu hóa hiệu suất làm việc nhóm.

Bảng X

BẢNG PHÂN CÔNG NHIỆM VỤ CHI TIẾT VÀ VAI TRÒ KỸ THUẬT

STT	Thành viên	Chi tiết các nhiệm vụ đảm nhận
1	Đoàn Phú	• Data Cleaning: Xử lý hậu kỳ dữ liệu, chuẩn hóa trường Tags. • Project Structure: Thiết kế cấu trúc thư mục chuẩn Python. • Session Management: Cấu hình lưu/ nạp Cookies.
2	Lâm Trần Tấn Phát	• Core Engine: Phát triển thuật toán Crawl và Infinite Scroll. • Database Module: Xây dựng driver kết nối MongoDB. • Asset Handler: Tải xuống và xử lý hình ảnh Avatar.
3	Đỗ Quốc Khánh	• Code Reviewer: Kiểm soát chất lượng và Merge code. • Data Integrity: Kiểm tra tính toàn vẹn file JSON. • Finalization: Rà soát dữ liệu cuối cùng.

B. Minh chứng đóng góp và Hoạt động chi tiết

Phần này trình bày các bằng chứng xác thực về mức độ đóng góp của từng thành viên thông qua lịch sử commit trên GitHub, kèm theo phân tích chi tiết về các đóng góp kỹ thuật quan trọng.

1) Thành viên: Đoàn Phú - Phụ trách Xử lý dữ liệu và Cấu hình: Thành viên Đoàn Phú tập trung vào việc chuẩn hóa dữ liệu thô và thiết lập môi trường nền tảng cho Bot.

- **Xử lý Tags:** Dữ liệu Tags thu về thường ở dạng chuỗi hỗn hợp. Đoàn Phú đã viết các hàm Regex để tách chuỗi, loại bỏ ký tự rác và chuyển đổi thành mảng (Array) tiêu chuẩn, giúp việc truy vấn theo chủ đề trở nên khả thi.
- **Quản lý Session:** Để tránh việc phải quét mã QR đăng nhập liên tục mỗi khi chạy lại Bot, thành viên này đã tích hợp cơ chế lưu Cookies vào file local và tự động load lại khi khởi động WebDriver.

Commits on Dec 22, 2025		
Merge pull request #12 from PhuDoan23/main	Verified	7645d38
Merge branch 'lamphat344961-alt:main' into main	Verified	3716a99
Update cookies path		66a2b48
Commits on Dec 21, 2025		
Merge pull request #11 from PhuDoan23/main	Verified	915dada
Update		c85a0ee
Commits on Dec 20, 2025		
Update project		c166f30

Hình 13. Các commit liên quan đến cập nhật cấu trúc

Commits on Dec 25, 2025		
Merge pull request #16 from PhuDoan23/main	Verified	267168a
Update		a440463
Update		5ed520b
Update		1706066
Update project structure		5467661
Commits on Dec 22, 2025		

Hình 14. Lịch sử xử lý Cookies và làm sạch Tags

2) *Thành viên: Lâm Trần Tấn Phát - Phụ trách Core Backend:* Đây là thành viên chịu trách nhiệm chính về "trái tim" của hệ thống Crawler. Các đóng góp kỹ thuật nổi bật bao gồm:

- **Logic Cuộn trang thông minh:** Thay vì cuộn trang cố định, Lâm Trần Tấn Phát đã cài đặt thuật toán cuộn ngẫu nhiên (Random Scroll) kết hợp với cơ chế chờ (Explicit Wait) để đảm bảo toàn bộ dữ liệu Lazy Loading được tải xuống đầy đủ trước khi trích xuất.
- **Kết nối Database:** Xây dựng module ‘database.py’ sử dụng thư viện ‘pymongo’, đảm bảo kết nối ổn định và xử lý các ngoại lệ khi lưu trữ hàng nghìn bản ghi cùng lúc.

Commits on Dec 20, 2025		
Merge pull request #10 from PhuDoan23/main	Verified	73ab059
Merge branch 'main' into main	Verified	296588f
hoàn thành lọc quốc gia và giá		400ac2b
update lọc quốc gia và giá		a709604
thêm file data vào .gitignore		31c1a49
Commits on Dec 18, 2025		
thêm geckodriver.exe		b4a00c4
thêm cấu hình		d6a5523
Update		f89bd4f
thêm vòng lặp và scroll để crawl và xuất excel		87720a4

Hình 15. Commit log của module Crawler và Scroll

Commits on Dec 22, 2025		
thêm kết nối lưu data base		184ff17
thêm file avatar_encoder và hàm download image		3118a42
cập nhật hàm crawl và bỏ lọc giá >300		733b207
thêm câu hình ca nhân		8449f75
Merge pull request #13 from dqk2210/main	Verified	1194f3d

Hình 16. Hiện thực hóa kết nối MongoDB và tải ảnh

3) *Thành viên: Đỗ Quốc Khánh - Phụ trách QA và Tích hợp:* Đóng vai trò là người chốt chặn cuối cùng (Gatekeeper) của dự án, Đỗ Quốc Khánh đảm bảo mã nguồn sạch và dữ liệu đầu ra đạt chuẩn.

- **Review và Merge:** Quản lý quy trình Git Flow, giải quyết các xung đột mã nguồn (Merge Conflicts) khi gộp code từ máy của Phú và Phát vào nhánh chính (Main Branch).
- **Kiểm tra JSON:** Phát triển các script nhỏ để validate file JSON đầu ra, đảm bảo các trường bắt buộc (như ID, Name) không bị null trước khi chuyển giao cho đội phân tích dữ liệu.

Commits on Dec 22, 2025		
Merge branch 'lamphat344961-alt:main' into main	Verified	a27175a
hoàn thành		f15af12
Merge branch 'main' of https://github.com/dqk2210/PPK_OSOS_Khanh		6aeb071
hoàn thành		6289635
Commits on Dec 19, 2025		
Merge pull request #9 from dqk2210/main	Verified	6e79b34
update lay tag		2d845db
Merge pull request #6 from dqk2210/main	Verified	12ca85e
update tag		573afef

Hình 17. Lịch sử Review code và Merge nhánh

Commits on Dec 25, 2025		
Merge pull request #15 from dqk2210/main	Verified	f5bee5d
Merge branch 'main' of https://github.com/dqk2210/PPK_OSOS_Khanh		490476b
update		5058017
Delete tiktok_ads_db_creators_vn1.json	Verified	905a028
data		f01a45e
Merge pull request #14 from dqk2210/main	Verified	1b46a48
final		91e8a62

Hình 18. Các commit chuẩn hóa dữ liệu cuối cùng