

Thu thập dữ liệu nhà sáng tạo nội dung TikTok từ TikTokOne bằng Selenium và MongoDB

Lâm Trần Tấn Phát Đỗ Quốc Khánh Đoàn Phú

Đại học Công nghệ TP.HCM (HUTECH)
Khoa Khoa học Dữ liệu

GVHD: ThS. Lê Nhật Tùng

Ngày 28 tháng 12 năm 2025

Nội dung trình bày

1. Giới thiệu
2. Phương pháp nghiên cứu
3. Kết quả phân tích
4. Thảo luận & Kết luận

Tổng quan vấn đề

Bối cảnh:

- **TikTok** bùng nổ, trở thành kênh tiếp thị (Influencer Marketing) quan trọng.
- Các nhãn hàng cần dữ liệu để chọn KOLs/KOCs phù hợp.

Thách thức:

- **TikTokOne (Creator Marketplace)** chứa dữ liệu chính xác nhưng khó truy cập thủ công.
- Website sử dụng công nghệ tải động (Dynamic loading), chặn request thông thường.

Mục tiêu và Công nghệ


Mục tiêu nghiên cứu:

- Xây dựng quy trình thu thập dữ liệu tự động (Automation).
- Phân tích xu hướng (EDA) từ dữ liệu thu thập được.

Công nghệ sử dụng:

- **Selenium:** Tự động hóa trình duyệt, vượt qua cơ chế tải động và lazy loading.
- **MongoDB:** Cơ sở dữ liệu NoSQL, lưu trữ dữ liệu JSON linh hoạt, phi cấu trúc.

Kiến trúc hệ thống (Pipeline)



Hình: Sơ đồ quy trình ETL (Extract - Transform - Load)

Quy trình thu thập (Crawling Strategy)

Chiến thuật Crawler:

1. **Khởi tạo:** Selenium WebDriver + Cookies đăng nhập (tránh Captcha).
2. **Bộ lọc:** Region = Vietnam.
3. **Vòng lặp thu thập:**
 - Quét các thẻ div chứa thông tin Creator.
 - Trích xuất ID, check trùng lặp với MongoDB (S_{cache}).
 - Lưu dữ liệu thô vào DB.
4. **Điều hướng thông minh:**
 - Cuộn trang (Infinite Scroll) để kích hoạt Lazy Load.
 - Random sleep (2-3s) để tránh bị chặn (Anti-ban).


Tiền xử lý dữ liệu (Preprocessing)

Dữ liệu thô từ web cần được làm sạch để phân tích:

Trường	Dữ liệu thô	Dữ liệu sạch
Followers	"2.5M", "500K"	2,500,000, 500,000 (Float)
Start Price	"1.200.000 VND"	1,200,000 (Float)
Engagement	"5.8%"	0.058 (Float)
Tags	List string	JSON Array

Bảng: Ví dụ chuyển đổi dữ liệu


1. Phân tích dữ liệu khuyết (Missing Values)



Nhận xét:

- Cột **Price** thiếu hụt **> 60%**.
- **Nguyên nhân:** Văn hóa "Inbox để biết giá" hoặc giá thỏa thuận.
- **Xử lý:** Đây là "Khuyết có thông tin" (Informative Missingness). Không xóa, mà dùng để phân loại nhóm (Có giá vs. Không giá).


2. Phân phối các chỉ số chính



Hình: Phân phối Followers, Engagement và Collab Score

- **Followers:** Phân phối lệch, chủ yếu là Micro-Influencers (10^5).
- **Engagement:** Lệch phải mạnh, đa số $< 5\%$. Tương tác cao ($> 20\%$) rất hiếm.


3. Tương tác theo Chủ đề (Tags)



Insight:

- **Giải trí thăng thế:** Tags *Selfie*, *Lip-sync*, *Dancing* có tương tác cao nhất ($\approx 8\%$).
- **Chuyên môn thấp hơn:** *Gaming*, *Tutorial*, *News* có tương tác ổn định nhưng thấp hơn (3 – 4%).


4. Ma trận tương quan



Kết quả bất ngờ:

- Các chỉ số **độc lập tuyến tính** ($r \approx 0$).
- *Followers* tăng không đồng nghĩa *Price* hay *Engagement* tăng tuyến tính.
- Cần mô hình phi tuyến tính (Random Forest, XGBoost) để dự báo giá.

5. Tác động của Công khai giá



Hình: So sánh lượng Follower: Công khai giá vs. Không công khai

Kết luận: Nhóm **Công khai giá** có xu hướng sở hữu lượng Follower cao hơn (thể hiện sự chuyên nghiệp và quy mô).

Thảo luận

1. **Sự "mờ đục" của thị trường:** Missing Price phản ánh chiến lược kinh doanh hơn là lỗi dữ liệu.
2. **Nghịch lý nội dung:** Nội dung giải trí ngắn (Short-form entertainment) dễ viral hơn nội dung chuyên sâu.
3. **Định giá Influencer:** Không thể dùng công thức tuyến tính đơn giản ($\text{Follower} \times \text{Đơn giá}$). Giá trị phụ thuộc vào định tính (Thương hiệu, Tập fan).

Kết luận và Hướng phát triển

Kết quả đạt được:

- Xây dựng thành công Bot thu thập dữ liệu ($N = 9000+$ mẫu).
- Làm rõ bức tranh thị trường TikTok Creator tại Việt Nam qua dữ liệu.

Hướng phát triển:

- Áp dụng Machine Learning để điền khuyết dữ liệu Price.
- Phân tích nội dung Video (Computer Vision) để đánh giá chất lượng thay vì chỉ dựa vào số liệu.
- Mở rộng sang các nền tảng khác (Instagram, YouTube).